

Highlights

Forecasting Local Coffee Price Volatility in Bahia with Cross-Commodity and Financial Information

Marcos Batista Figueredo, Alarcon Matos de Oliveira, Alexandre do Nascimento Silva, Roberto Luiz Souza Monteiro, Thiago Barros Murarri, Eugenio Rocha da Silva Junior, Uanderson Lima Santos, José Gileá de Souza, Marcos Antônio Vanderlei Silva

- GARCH and HAR-RV beat machine learning for local coffee volatility in Bahia.
- Cross-commodity information yields only marginal, model-specific gains.
- Financial information hurts forecasts in calm regimes but helps in volatile ones.
- Rankings are robust to zero-variance targets from infrequent price updates.
- High SHAP importance of interest rates does not imply predictive value.

Forecasting Local Coffee Price Volatility in Bahia with Cross-Commodity and Financial Information

Marcos Batista Figueredo^{a,*}, Alarcon Matos de Oliveira^a, Alexandre do Nascimento Silva^a, Roberto Luiz Souza Monteiro^a, Thiago Barros Murarri^b, Eugenio Rocha da Silva Junior^a, Uanderson Lima Santos^a, José Gileá de Souza^a and Marcos Antônio Vanderlei Silva^a

^aUniversidade do Estado da Bahia, Bahia, Brazil

^bUniversidade SENAI-CIMATEC, Bahia, Brazil

ARTICLE INFO

Keywords:

coffee price volatility
agricultural commodities
machine learning
temporal validation
Brazil
risk forecasting

ABSTRACT

Coffee price volatility exposes producers, cooperatives, traders and financial institutions in regional markets to income and risk-management uncertainty, yet evidence on forecasting volatility in local Brazilian coffee markets is scarce. This study evaluates whether cross-commodity and financial information improves out-of-sample forecasts of future volatility for three local coffee price series in Bahia, Brazil: Arabica in Vitória da Conquista and Luís Eduardo Magalhães and Conilon in Eunápolis (14,126 observations, 2001–2026). Six research questions compare econometric and machine-learning models, isolate the contribution of each information block, and examine regime dependence and the drivers of the forecasts. GARCH(1,1) and HAR-RV benchmarks are compared with Random Forest, XGBoost and LightGBM estimated on four nested information sets under an expanding-window design with purged labels, at horizons of one, five and twenty observations. Forecasts are evaluated with QLIKE, MAE and RMSE, Diebold–Mariano tests with the Harvey–Leybourne–Newbold correction and multiple-testing adjustments, ex-ante volatility regimes and SHAP. The econometric benchmarks are not beaten: GARCH yields the lowest QLIKE and HAR-RV the lowest MAE and RMSE at all horizons, a ranking that is robust to the treatment of the many zero-variance targets produced by infrequent price updates. Cross-commodity information yields marginal gains restricted to Random Forest. Financial information worsens forecasts on average, but its value is regime dependent: it degrades forecasts in calm periods and adds information when volatility is high. The high SHAP importance of interest-rate levels does not translate into out-of-sample gains. The findings support loss-specific, benchmarked model selection in local agricultural risk forecasting.

1. Introduction

A volatilidade dos preços agrícolas constitui uma importante fonte de risco para produtores, cooperativas, exportadores, instituições financeiras e formuladores de políticas públicas (Manogna, Dharmaji and Sarang, 2025; Brun, 2026). No caso do café, oscilações acentuadas nos preços podem afetar a renda dos produtores, as decisões de comercialização, a necessidade de proteção financeira e o planejamento da produção (Zhang, Zhang and Lee, 2025; Chaovanapoonphol, Singvejsakul and Wiboonpongse, 2023; Fahmi, Febriani, Rasyid and Hakim, 2023). Além disso, a crescente integração entre mercados agrícolas, cambiais, energéticos e financeiros faz com que a dinâmica de preços do café seja influenciada não apenas por condições locais de oferta e demanda, mas também por choques originados em outros mercados (Nassani, Imran, Khan, Zaman, Khan and Haffar, 2025; R.L. and Lahiri, 2025).

Os preços de commodities agrícolas (Hamulczuk, Pawlak and Czech, 2026; Manogna et al., 2025; Jin and Xu, 2026; Kupabado and Kaehler, 2025; Martin and Clapp, 2015) apresentam características típicas de mercados financeiros (Budris, Handro and Dima, 2025), como agrupamento de volatilidade (Naivasha, Musumba, Gikunda and Wandeto, 2026), distribuições com caudas pesadas (Seo, Jeong, Kim and Lee, 2026), não linearidade e mudanças estruturais. Modelos da família GARCH (Ma and Wei, 2025; Mohamed, Ismail and Majahar Ali, 2025; Maulana, Sumarminingsih, Nurjannah, Astuti and Astutik, 2026) permanecem amplamente utilizados para representar a variância condicional e a persistência da volatilidade, inclusive em estudos específicos sobre café. Modelos GARCH com variáveis exógenas mostram que fatores relacionados à produção, ao comércio internacional e aos países concorrentes podem alterar significativamente a volatilidade do café (Chaovanapoonphol et al., 2023). Entretanto, evidências recentes também

*Corresponding author
ORCID(s):

indicam que especificações GARCH tradicionais podem apresentar limitações em períodos de instabilidade e em situações caracterizadas por assimetria e risco extremo (Brun, 2026).

Paralelamente, métodos de machine learning vêm sendo utilizados para modelar relações não lineares e interações complexas em séries temporais agrícolas (Kumar and Tripti, 2026; Zhang et al., 2025; Jin and Xu, 2024). Estudos recentes aplicam modelos híbridos que combinam redes neurais e modelos econométricos, obtendo ganhos em relação a especificações isoladas em determinados mercados e horizontes (Manogna et al., 2025; Nhlapo, Atemkeng and Ndogmo, 2025). Outras pesquisas mostram que a inclusão de variáveis exógenas, como condições climáticas e indicadores econômicos, pode melhorar a previsão de preços agrícolas em comparação com modelos univariados (Nayak, Alam, Singh, Avinash, Kumar, Ray and Deb, 2024; Zhang et al., 2025; Pandit, Sagar, Ghose, Paul, Kisi, Vishwakarma, Mansour and Yadav, 2024). Revisões recentes, contudo, ressaltam que os resultados dependem do mercado analisado, da frequência dos dados, do horizonte de previsão, da especificação dos modelos e da estratégia de validação utilizada (Guindani, Oliveirai, Ribeiro, Gonzalez and de Lima, 2024).

A interconectividade entre commodities e mercados financeiros globais é fortemente dependente de choques e regimes, pois períodos de crise intensificam a transmissão de retornos, volatilidade e risco extremo em diferentes frequências, alterando a direção e a assimetria dos fluxos entre mercados centrais e regionais (Khemakhem and Gallas, 2025; Diebold and Yilmaz, 2012, 2014; Baruník and Křehlík, 2018). Petróleo, café, açúcar, borracha e outras commodities agrícolas exibem spillovers de volatilidade mais intensos durante crises econômicas e financeiras (Singh and Kumar, 2026). As conexões também podem ser bidirecionais, com mercados financeiros e commodities alternando os papéis de transmissores e receptores de choques; em episódios de estresse, os spillovers de curto prazo tendem a dominar, enquanto mercados centrais, especialmente os Estados Unidos, aparecem frequentemente como transmissores persistentes (Zhou, Ouyang, Gupta and Ji, 2026). Essas relações podem conter informação preditiva adicional para a volatilidade futura de um determinado ativo.

Apesar desses avanços, permanecem três limitações importantes. Primeiro, grande parte dos estudos existentes concentra-se em preços internacionais, contratos futuros, índices agregados ou mercados financeiros desenvolvidos (Zhou et al., 2026; Pandit et al., 2024; Brun, 2026). Segundo, muitos trabalhos priorizam a previsão do nível ou da direção dos preços, em vez da previsão direta da volatilidade futura (Jin and Xu, 2024; Chaovanapoonphol et al., 2023; Aliaga-Miranda, Flores-Vilcapoma, Callupe-Cueva, Mariños-Alfaro, Visurraga-Camargo and Chavarry-Becerra, 2026). Terceiro, a contribuição relativa da informação local, cross-commodity e financeira raramente é separada de forma sistemática (R.L. and Lahiri, 2025). Como resultado, ainda não está claro quais blocos de informação efetivamente aumentam a previsibilidade da volatilidade em mercados agrícolas regionais.

Estudos recentes indicam que a previsibilidade da volatilidade em mercados agrícolas regionais pode aumentar quando o modelo incorpora blocos de informação exógena e de transmissão espacial, e não apenas o histórico de preços (Lambert, Schoeneman, Lambert and Brienen, 2025). Em especial, clima, choques geopolíticos, pressão da cadeia de suprimentos, câmbio, energia, política comercial e sinais de informação local/fluxos de mercado aparecem repetidamente como variáveis que melhoram o forecast da volatilidade agrícola (Salisu, Ogbonna, Gupta and Bouri, 2025; Salisu and AbdulHakeem, 2026; Capitani and Gaio, 2025; Marín-Rodríguez, González-Ruíz and Botero, 2025).

Ao mesmo tempo, políticas locais podem ter capacidade limitada para controlar oscilações determinadas por forças externas de oferta, demanda e integração de mercados (Fahmi et al., 2023; Aliaga-Miranda et al., 2026). No caso brasileiro, e particularmente no estado da Bahia, ainda são escassas as evidências quantitativas sobre a previsão da volatilidade de preços locais de café utilizando simultaneamente informações da própria praça, de outras commodities agrícolas e dos mercados financeiros (Capitani and Gaio, 2025; Torre, Tonin and Oñate-Paredes, 2025; da Cunha and Wander, 2014; da Costa Júnior, Khan, de Sousa and Sales Lima, 2015).

Uma inspeção descritiva das séries mostra que a intensidade do risco varia substancialmente entre as praças. A Figure 1 apresenta o percentil 90 mensal da volatilidade histórica calculada em uma janela de vinte observações entre 2019 e 2024. Os valores foram calculados a partir das cotações da SEAGRI-BA, e as lacunas correspondem a meses sem observações suficientes. O episódio destacado entre junho e agosto de 2021 registra aproximadamente 56% na série Arábica de Vitória da Conquista, enquanto os picos correspondentes permanecem próximos de 31% em Luís Eduardo Magalhães e 11% em Eunápolis. Essa heterogeneidade constitui a motivação empírica para investigar se informações locais, cross-commodity e financeiras melhoram a previsão da volatilidade futura.




Figure 1. Observed upper-tail volatility of local coffee prices in Bahia, Brazil.

Diante dessa lacuna, o **objetivo** deste estudo é avaliar se informações de outras commodities agrícolas e dos mercados financeiros melhoram a previsão fora da amostra da volatilidade futura dos preços locais de café Arábica e Conilon na Bahia, em relação a modelos que utilizam apenas o histórico da própria praça. A análise utiliza três séries locais da SEAGRI-BA, correspondentes ao café Arábica em Vitória da Conquista, ao café Arábica em Luís Eduardo Magalhães e ao café Conilon em Eunápolis. Para atingir esse objetivo, o estudo responde a seis perguntas de pesquisa:

- RQ1.** Os modelos de machine learning apresentam desempenho superior aos modelos econométricos tradicionais (GARCH e HAR-RV) na previsão da volatilidade local do café?
- RQ2.** A inclusão de informações de outras commodities (café internacional, indicador CEPEA, soja, algodão e cacau) melhora a previsão em relação ao histórico próprio?
- RQ3.** Variáveis financeiras e macrofinanceiras (câmbio, juros, petróleo, volatilidade financeira e índices acionários) fornecem ganho preditivo adicional?
- RQ4.** O desempenho relativo dos modelos e o valor da informação externa diferem entre regimes de baixa, média e alta volatilidade?
- RQ5.** Quais variáveis e blocos de informação mais contribuem para as previsões de cada variedade?
- RQ6.** Os fatores relevantes são semelhantes entre Arábica e Conilon ou específicos de cada variedade?

As perguntas são tratadas como uma avaliação empírica fora da amostra, sem pressupor a direção dos efeitos. Resultados nulos ou negativos são, portanto, informativos para a seleção de modelos e de fontes de informação. RQ1 compara famílias de modelos; RQ2 e RQ3 isolam o valor de cada bloco de informação; RQ4 examina a estabilidade desses resultados; e RQ5 e RQ6 identificam os fatores associados às previsões.

O desenho empírico compara GARCH(1,1) e HAR-RV com Random Forest, XGBoost e LightGBM, estimados sobre quatro conjuntos de informação aninhados. E1 utiliza apenas o histórico próprio, E2 acrescenta variáveis cross-commodity, E3 acrescenta variáveis financeiras e E4 reúne todos os blocos. Essa estrutura separa o efeito do algoritmo do efeito da informação. A avaliação utiliza validação temporal estrita em janela crescente, horizontes de uma, cinco e vinte observações, as perdas QLIKE, MAE e RMSE, testes de Diebold–Mariano com correção de Harvey–Leybourne–Newbold e correção para múltiplas comparações, análise por regimes definidos ex ante e explicabilidade por importâncias nativas e valores SHAP (*Shapley Additive exPlanations*) (Wang, Chen, Zhu and Xie, 2024; Diachkov and Ashofteh, 2026).

O estudo oferece três contribuições. Primeiro, fornece evidência fora da amostra sobre a previsão da volatilidade de preços locais de café em um mercado emergente, caracterizado por cotações pouco frequentes e longas lacunas, condição pouco explorada pela literatura concentrada em contratos futuros e índices internacionais. Segundo, quantifica o valor incremental de cada bloco de informação por meio de experimentos de ablação controlados, em vez de apenas ordenar algoritmos. Terceiro, mostra que benchmarks econométricos simples permanecem difíceis de superar nesse contexto e que a importância atribuída a variáveis financeiras pelos modelos não se converte em ganho preditivo, um alerta relevante para aplicações de machine learning em finanças agrícolas.

O restante do artigo está organizado da seguinte forma. A Section 2 descreve os dados, as medidas de volatilidade, os modelos e o protocolo de validação. A Section 3 apresenta os experimentos e seus resultados, organizados pelas perguntas de pesquisa. A Section 4 discute os resultados à luz da literatura e apresenta as limitações, e a Section 5 conclui.

2. Materials and Methods

Esta seção descreve um desenho observacional em duas camadas. A primeira organiza as cotações locais, as commodities relacionadas e os indicadores financeiros em um painel temporal. A segunda utiliza blocos aninhados de atributos para produzir previsões fora da amostra da volatilidade futura dos preços locais de café com modelos econométricos e de machine learning. Assim, os resultados são interpretados como evidência de conteúdo informacional incremental e não como uma decomposição causal da volatilidade.

2.1. Desenho do estudo

O estudo é quantitativo, longitudinal e baseado em séries temporais de preços observados. O desenho empírico combina uma unidade de previsão local com uma representação relacional dos mercados. A unidade de previsão é uma cotação disponível para uma combinação de variedade e praça, identificada por c e pela data t . Para cada unidade, são observados o preço local, os retornos passados, as medidas históricas de volatilidade, as variáveis externas disponíveis e a volatilidade futura associada ao horizonte h . Formalmente, o conjunto de observações destinado à série c é

$$D_c = \left\{ (t, P_{c,t}, \mathbf{x}_{c,t}, V_{c,t,h}) \mid t \in \mathcal{T}_c, h \in \{1, 5, 20\} \right\}. \quad (1)$$




Figure 2. Study workflow: data preparation, volatility measures, nested information sets, model estimation, expanding-window forecasting and downstream analyses.

O fluxo apresentado na Figure 2 organiza a análise em seis blocos. A preparação dos dados estrutura as observações locais e externas em uma base temporal comum. As medidas de retorno e volatilidade transformam preços em atributos comparáveis entre unidades e definem o alvo de previsão. Os conjuntos de informação aninhados E1–E4 separam o histórico próprio, a informação cross-commodity e a informação financeira. Os modelos econométricos e de machine learning são estimados sobre esses conjuntos, e a previsão em janela crescente produz as estimativas fora da amostra para os horizontes de um, cinco e vinte observações. Por fim, as análises downstream avaliam desempenho preditivo, significância estatística, heterogeneidade entre mercados e regimes e importância das variáveis.

Como as séries locais apresentam dias sem atualização e longos intervalos sem observação, não foi criada uma grade diária artificial. Cada horizonte é contado em observações sucessivas da própria série-alvo. Essa decisão preserva a natureza dos dados e evita transformar períodos sem cotação em retornos sintéticos.

As variáveis dependentes são o café Arábica nas praças de Vitória da Conquista e Luís Eduardo Magalhães e o café Conilon na praça de Eunápolis. Para tornar a comparação internamente consistente, foi selecionado o tipo Rio para as duas séries de Arábica e o tipo 7 para a série de Conilon. Após o tratamento descrito nesta seção, o painel contém 14.126 observações distribuídas entre as três séries.

Os preços são expressos em reais por saca de 60 kg. Os retornos e as medidas $HVol_5$ e V_{20} estão em pontos percentuais. O horizonte de vinte períodos corresponde às próximas vinte observações disponíveis da série local.

Table 1

Characteristics of the local series used as dependent variables

Série	Tipo	N	Período	$s(r_t)$	Mediana $HVol_5$	Mediana V_{20}
Arábica, Vitória da Conquista	Rio	4.427	2001-12-03 a 2026-01-21	3,126	2,410	6,899
Arábica, Luís Eduardo Magalhães	Rio	4.195	2003-02-05 a 2026-01-21	3,066	0,000	6,899
Conilon, Eunápolis	Tipo 7	5.504	2001-12-14 a 2026-01-21	1,962	1,170	4,455

2.2. Fontes de dados e variáveis observadas

Os preços locais foram obtidos da Secretaria da Agricultura, Pecuária, Irrigação, Pesca e Aquicultura da Bahia, identificada como SEAGRI-BA. O preço nacional de referência foi obtido do Centro de Estudos Avançados em Economia Aplicada, com séries de café Arábica e café Robusta. Os contratos futuros internacionais foram obtidos por meio das séries contínuas disponibilizadas pelo Yahoo Finance. Foram utilizados o contrato de café ICE Coffee C KC=F, soja ZS=F, algodão CT=F e cacau CC=F. Essas séries são tratadas como referências de mercado e não como substitutas automáticas de uma série oficial de contratos individuais, pois a convenção de continuidade e de rolagem pertence à fonte de dados.

As variáveis financeiras e macrofinanceiras foram combinadas a partir de fontes públicas. A taxa USD/BRL e a taxa SELIC anualizada para 252 dias foram obtidas do Banco Central do Brasil. O índice de volatilidade VIX, o índice amplo do dólar, a taxa dos títulos do Tesouro dos Estados Unidos com maturidade de dez anos e a taxa efetiva dos Fed Funds foram obtidos do Federal Reserve Economic Data. O preço spot do Brent foi obtido da U.S. Energy Information Administration. Os retornos do S&P 500 e do Ibovespa foram calculados a partir das séries históricas correspondentes.

Antes da integração das fontes, foi realizada uma auditoria automatizada de 74 séries candidatas provenientes da SEAGRI-BA, CEPEA, Banco Central do Brasil, Federal Reserve Economic Data, CBOE, U.S. Energy Information Administration e Yahoo Finance. Foram registrados a cobertura temporal, a frequência, o número de observações, os valores ausentes, as duplicatas, a proporção de preços inalterados, os maiores intervalos entre observações, a cobertura de dias úteis, as alterações de unidade e as anomalias iniciais. A triagem classificou 31 séries como inicialmente utilizáveis e 43 como não utilizáveis, principalmente por cobertura insuficiente, lacunas extensas ou inconsistência de unidade.

A análise exploratória mostrou que as medianas dos preços locais são 300,00, 310,00 e 247,00 reais por saca de 60 kg para Vitória da Conquista, Luís Eduardo Magalhães e Eunápolis, respectivamente. Os desvios-padrão dos retornos são 3,126, 3,066 e 1,962 pontos percentuais, enquanto as medianas de V_{20} são 6,899, 6,899 e 4,455 pontos percentuais (Table 1). Nas 3.958 datas comuns das duas séries de Arábica, os preços coincidem em 12,86% das datas, a correlação entre retornos é 0,137 e apenas 5,38% das datas registram variação simultânea. Esses resultados indicam que as praças não devem ser tratadas como duplicatas da mesma série.

A frequência efetiva de atualização também é baixa: os preços permanecem inalterados em 77,48% das observações de Vitória da Conquista, 87,56% de Luís Eduardo Magalhães e 84,10% de Eunápolis. No suporte comum de avaliação, a volatilidade futura é exatamente nula em 76,9%–88,4% das origens para $h = 1$, em 36,6%–53,0% para $h = 5$ e em 5,8%–10,0% para $h = 20$, dependendo da série. Essa característica condiciona a avaliação pela QLIKE e é tratada nas análises de robustez. Os maiores intervalos entre observações foram de 374 dias em Vitória da Conquista, 812 dias em Luís Eduardo Magalhães e 217 dias em Eunápolis; por isso, não foi criada uma grade diária artificial e os horizontes são contados em observações sucessivas.

As datas foram convertidas para o formato temporal padrão, os registros foram ordenados e duplicatas foram agrupadas por data, mantendo-se a última cotação registrada. Não foi aplicada interpolação linear aos preços: a ausência de uma cotação não foi interpretada como estabilidade e não foi preenchida com uma observação futura. Foram removidos o dia 1 de janeiro em todos os anos, o registro de 31 de agosto de 2023, identificado como falha comum do fluxo da SEAGRI-BA, e um ponto isolado de 28 de julho de 2010 em Vitória da Conquista, caracterizado por salto e retorno imediato compatível com erro decimal. Retornos absolutos superiores a 40% foram mantidos e marcados por `is_extreme_return`, pois podem representar movimentos informativos para o estudo da volatilidade.

No painel final, a série CEPEA apresenta 58,18% de valores ausentes por iniciar em 2016. Os percentuais de ausência são 0,35% para o retorno USD/BRL, 2,36% para o VIX, 1,85% para o retorno do Brent, 2,79% para o retorno da soja, 2,96% para o retorno do algodão e 2,97% para o retorno do cacau. O padrão de ausência foi preservado para que a contribuição incremental de cada bloco fosse avaliada sob uma regra comum de amostra e imputação.

Cada série exógena foi transformada em seu próprio calendário antes da integração. Para uma data t da série-alvo, a observação exógena utilizada é

$$x_{j,t}^* = x_{j,\tau_j(t)}, \quad \tau_j(t) = \max \{s \leq t \mid t - s \leq 7 \text{ dias}\}. \quad (2)$$

Quando não existe uma observação s que satisfaça a condição da Equação 2, o valor permanece ausente. A integração foi realizada por uma junção temporal para trás com tolerância de sete dias. O procedimento utiliza somente a informação disponível até a data de previsão e evita o preenchimento silencioso através de lacunas prolongadas.

2.3. Retornos e medidas de volatilidade

Os retornos logarítmicos definem a unidade estatística utilizada para representar a dinâmica dos preços e a variável-alvo da previsão. Eles reduzem o efeito da escala nominal e permitem comparar as praças locais com as commodities e os mercados financeiros. A partir desses retornos, as medidas históricas resumem a intensidade recente das variações e alimentam os modelos com informação disponível na origem t , enquanto a soma de retornos futuros constrói o alvo para cada horizonte. Essa separação entre informação passada e variação futura é fundamental para evitar vazamento temporal e interpretar os ganhos dos blocos adicionais de informação.

Para cada série c , seja $P_{c,t} > 0$ o preço observado na t -ésima cotação. O retorno logarítmico, expresso em pontos percentuais, é

$$r_{c,t} = 100 \ln \left(\frac{P_{c,t}}{P_{c,t-1}} \right). \quad (3)$$

O retorno na primeira observação de cada série é ausente. Para as séries exógenas de preços, a mesma transformação foi aplicada em seus calendários nativos antes da junção temporal.

As medidas históricas de variação utilizadas como atributos foram calculadas exclusivamente com retornos disponíveis até t . Para uma janela k , define-se

$$HVar_{c,t,k} = \sum_{j=0}^{k-1} r_{c,t-j}^2 \quad (4)$$

e

$$HVol_{c,t,k} = \sqrt{HVar_{c,t,k}}. \quad (5)$$

Foram utilizadas as janelas $k \in \{5, 10, 20\}$. Essas medidas não são calculadas com retornos futuros e, portanto, podem ser utilizadas como informação disponível no instante t .

A variável dependente representa a intensidade acumulada das variações futuras. Para cada horizonte $h \in \{1, 5, 20\}$, define-se a variação quadrática futura

$$Q_{c,t,h} = \sum_{i=1}^h r_{c,t+i}^2 \quad (6)$$

e a volatilidade futura agregada

$$V_{c,t,h} = \sqrt{Q_{c,t,h}}. \quad (7)$$

O índice $t + i$ representa a próxima observação disponível da série-alvo, e não necessariamente o próximo dia do calendário. Os modelos supervisionados são ajustados diretamente para $V_{c,t,h}$. A quantidade $Q_{c,t,h} = V_{c,t,h}^2$ é utilizada na avaliação de perdas específicas para variância, especialmente QLIKE. Como as bases utilizadas são predominantemente diárias e não contêm retornos intradiários, o termo volatilidade futura agregada é preferido à interpretação de uma medida clássica de *realized volatility* intradiária.

Em conjunto, essas definições produzem a referência univariada do estudo. O conjunto de variáveis de histórico próprio $E1$ utiliza os retornos disponíveis, suas defasagens e $HVol_{c,t,5}$, $HVol_{c,t,10}$ e $HVol_{c,t,20}$. Essa especificação constitui o baseline de informação local para medir o ganho incremental de variáveis cross-commodity e financeiras. Em paralelo, GARCH(1,1) e HAR-RV adaptado funcionam como baselines econométricos, pois modelam a volatilidade exclusivamente a partir do histórico local sob hipóteses distintas sobre persistência e agregação temporal. Assim, esta subseção estabelece os preditores históricos, define o alvo futuro e garante a comparabilidade entre horizontes, enquanto as subseções seguintes avaliam se algoritmos e fontes de informação adicionais melhoram essa referência.

2.4. Construção dos atributos e conjuntos de informação

Os atributos da própria série incluem $r_{c,t}$, cinco defasagens do retorno e as três medidas históricas $HVol_{c,t,5}$, $HVol_{c,t,10}$ e $HVol_{c,t,20}$. Assim, o bloco de histórico próprio contém nove variáveis

$$\mathcal{I}_{c,t}^L = \{r_{c,t}, r_{c,t-1}, \dots, r_{c,t-5}, HVol_{c,t,5}, HVol_{c,t,10}, HVol_{c,t,20}\}. \quad (8)$$

O bloco cross-commodity contém o retorno e a volatilidade de cinco períodos da outra variedade local, os retornos e as volatilidades de cinco períodos de soja, algodão e cacau, além dos retornos do contrato internacional de café e do indicador nacional CEPEA

$$\mathcal{I}_t^C = \{r_t^{other}, HVol_{t,5}^{other}, r_t^{soy}, HVol_{t,5}^{soy}, r_t^{cotton}, HVol_{t,5}^{cotton}, r_t^{cocoa}, HVol_{t,5}^{cocoa}, r_t^{ICEcoffee}, r_t^{CEPEA}\}. \quad (9)$$

Para a variável de outra variedade, o retorno do Conilon corresponde à série de Eunápolis e o retorno de Arábica corresponde à média disponível das duas praças de Arábica. A média é calculada no calendário observado antes da junção com a série-alvo.

O bloco financeiro e macrofinanceiro é

$$\mathcal{I}_t^F = \{r_t^{USD/BRL}, HVol_{t,5}^{USD/BRL}, SELIC_t, VIX_t, \Delta VIX_t, r_t^{Brent}, r_t^{Dollar}, r_t^{S\&P500}, r_t^{Ibovespa}, Treasury10Y_t, FedFunds_t\}. \quad (10)$$

As quatro especificações de informação são

$$\mathcal{X}_t^{E1} = \mathcal{I}_{c,t}^L \quad (11)$$

$$\mathcal{X}_t^{E2} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^C \quad (12)$$

$$\mathcal{X}_t^{E3} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^F \quad (13)$$

$$\mathcal{X}_t^{E4} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^C \cup \mathcal{I}_t^F. \quad (14)$$

E1 representa o histórico próprio. E2 acrescenta informação cross-commodity. E3 acrescenta informação financeira. E4 contém todos os blocos. Essa estrutura permite estimar o ganho marginal de cada fonte sem confundir a comparação entre algoritmos com a comparação entre conjuntos de informação.

2.5. Modelos econométricos de referência

Os modelos econométricos constituem referências fundamentais para avaliar se os modelos de machine learning produzem ganho preditivo efetivo ou apenas exploram uma maior flexibilidade algorítmica. Essa comparação é particularmente importante em mercados agrícolas locais, nos quais o número de observações é limitado, as cotações podem permanecer inalteradas por vários períodos e a volatilidade apresenta persistência, agrupamento temporal e possíveis respostas assimétricas a choques. Um benchmark econométrico bem definido estabelece, portanto, o nível de previsibilidade que pode ser obtido apenas a partir do histórico local.

No caso do café, modelos da família GARCH são utilizados para representar a variância condicional de preços à vista e futuros, bem como a transmissão de choques entre mercados domésticos e internacionais. Estudos sobre café Arábica empregam especificações GARCH, EGARCH e TGARCH para identificar persistência e assimetria, enquanto modelos GARCH com variáveis exógenas incorporam fatores macroeconômicos e internacionais (Carvalho, Souza Silva, da Costa Lobato and Martins Figueiredo, 2023; Rahayu, Chang and Anindita, 2015; Chaovanapoonphol et al., 2023; Brun, 2026). O modelo HAR-RV, por sua vez, é utilizado na previsão da volatilidade realizada de commodities agrícolas, inclusive em bases que incluem contratos futuros de café (Corsi, 2009; Bonato, Cepni, Gupta and Pierdzioch, 2024). Entretanto, grande parte dessas aplicações utiliza dados intradiários e mercados futuros líquidos. Neste estudo, o HAR-RV é adaptado para séries locais diárias e pouco frequentes, nas quais a volatilidade é construída a partir dos retornos entre observações consecutivas.

Foram utilizados três modelos econométricos: GARCH(1,1), EGARCH(1,1,1) e HAR-RV adaptado. GARCH(1,1) e HAR-RV constituem as referências principais da comparação preditiva. O EGARCH é utilizado como análise de robustez, pois permite verificar se a possível assimetria entre choques positivos e negativos altera a avaliação dos benchmarks. Todos os modelos são estimados separadamente para as três séries-alvo: café Arábica em Vitória da Conquista, café Arábica em Luís Eduardo Magalhães e café Conilon em Eunápolis.

2.5.1. GARCH

O modelo GARCH(1,1) representa a volatilidade como uma variância condicional que evolui em função de choques recentes e de sua própria persistência (Bollerslev, 1986). Para cada série local c , o retorno é definido por

$$r_{c,t} = \sigma_{c,t} z_{c,t}, \quad z_{c,t} \sim \mathcal{N}(0, 1). \quad (15)$$

A variância condicional é

$$\sigma_{c,t}^2 = \omega + \alpha r_{c,t-1}^2 + \beta \sigma_{c,t-1}^2. \quad (16)$$

Os parâmetros são estimados no conjunto de treinamento de cada janela anual. A previsão da variação quadrática futura é obtida pela soma das variâncias condicionais previstas

$$\hat{Q}_{c,t,h}^{GARCH} = \sum_{i=1}^h \hat{\sigma}_{c,t+i|t}^2, \quad \hat{V}_{c,t,h}^{GARCH} = \sqrt{\hat{Q}_{c,t,h}^{GARCH}}. \quad (17)$$

O parâmetro ω representa o nível médio de variância, α mede a reação imediata a um choque recente e β representa a persistência da volatilidade. Valores elevados de $\alpha + \beta$, desde que compatíveis com a condição de estacionariedade, indicam que os choques tendem a desaparecer lentamente. A especificação utiliza somente os retornos locais e não recebe diretamente informações de soja, algodão, cacau, café internacional, câmbio, juros ou índices financeiros. Essa escolha define um benchmark puramente local para avaliar o ganho incremental dos modelos de machine learning.

2.5.2. EGARCH

Para representar possíveis respostas assimétricas a choques positivos e negativos, foi estimado um EGARCH(1,1,1) (Nelson, 1991). O modelo é utilizado como robustez econométrica, e não como benchmark principal.

$$\ln(\sigma_{c,t}^2) = \omega + \beta \ln(\sigma_{c,t-1}^2) + \alpha (|z_{c,t-1}| - \mathbb{E}|z_{c,t-1}|) + \gamma z_{c,t-1}. \quad (18)$$

O parâmetro α captura o efeito do tamanho do choque, enquanto γ mede sua assimetria. Sob a parametrização utilizada, valores negativos de γ indicam que choques negativos tendem a elevar a volatilidade mais intensamente do que choques positivos de mesma magnitude. A forma logarítmica da variância garante previsões positivas sem impor diretamente restrições de não negatividade aos parâmetros. Para $h > 1$, as previsões EGARCH foram obtidas por simulação de Monte Carlo com 1.000 trajetórias e semente 42. A comparação primária e os testes de superioridade preditiva utilizam somente previsões com suporte comum e excluem o EGARCH quando sua cobertura não é completa.

2.5.3. HAR-RV adaptado

O baseline HAR-RV foi implementado como uma regressão linear da volatilidade futura agregada sobre medidas de variação em escalas diária, semanal e mensal (Corsi, 2009; Bonato et al., 2024). Como as séries locais não possuem observações intradiárias, a especificação é denominada HAR-RV adaptado: ela preserva a lógica de múltiplas escalas, mas utiliza retornos entre observações consecutivas das cotações locais.

$$V_{c,t,h} = \beta_{0,h} + \beta_{d,h}|r_{c,t}| + \beta_{w,h}HV ol_{c,t,5} + \beta_{m,h}HV ol_{c,t,20} + \varepsilon_{c,t,h}. \quad (19)$$

Os coeficientes foram obtidos por mínimos quadrados ordinários exclusivamente no treinamento de cada janela. A especificação é uma adaptação do princípio HAR para a medida de volatilidade agregada disponível nas séries diárias. Foram exigidas pelo menos 250 observações de treinamento para estimar cada baseline.

O termo $|r_{c,t}|$ representa a escala diária, $HV ol_{c,t,5}$ aproxima a escala semanal e $HV ol_{c,t,20}$ aproxima a escala mensal. Como o alvo muda de acordo com h , são estimados coeficientes específicos para cada horizonte $h \in \{1, 5, 20\}$. A medida $HV ol_{c,t,10}$ é disponibilizada aos modelos de machine learning, mas não entra diretamente no HAR-RV, preservando uma especificação parsimoniosa e próxima da decomposição diária–semanal–mensal da literatura.

2.5.4. Integração com os conjuntos de informação

A separação entre os modelos econométricos e os conjuntos de informação dos modelos de machine learning foi feita de maneira deliberada. Os benchmarks GARCH, EGARCH e HAR-RV utilizam apenas informações locais, enquanto os modelos de machine learning são estimados com quatro conjuntos aninhados:

$$\mathcal{X}_t^{E1} = \mathcal{I}_{c,t}^L, \quad \mathcal{X}_t^{E2} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^C, \quad (20)$$

$$\mathcal{X}_t^{E3} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^F, \quad \mathcal{X}_t^{E4} = \mathcal{I}_{c,t}^L \cup \mathcal{I}_t^C \cup \mathcal{I}_t^F. \quad (21)$$

O bloco local $\mathcal{I}_{c,t}^L$ contém o retorno disponível, cinco defasagens do retorno e as volatilidades históricas de cinco, dez e vinte observações. O bloco cross-commodity inclui a outra variedade de café, o contrato internacional de café, o indicador CEPEA, soja, algodão e cacau. O bloco financeiro inclui USD/BRL, volatilidade do câmbio, SELIC, VIX, Brent, Dollar Index, S&P 500, Ibovespa, Treasury de dez anos e Federal Funds Rate.

As variáveis externas não são incluídas nos benchmarks econométricos na especificação principal. Assim, a comparação E1–E4 mede o valor incremental dos blocos de informação dentro dos modelos de machine learning, enquanto a comparação entre E0 e E1 avalia a diferença entre uma representação econométrica estruturada e uma representação baseada em árvores com o mesmo histórico local. Uma extensão GARCH-X ou HAR-X poderia ser analisada futuramente, mas sua inclusão no estudo atual misturaria, no mesmo benchmark, mudanças na forma funcional e mudanças no conjunto de informação.

2.5.5. Escolhas de especificação, parâmetros e robustez

A ordem GARCH(1,1) foi escolhida por ser uma especificação parsimoniosa e amplamente utilizada como referência para séries financeiras e de commodities. Ela contém um termo para o impacto do choque mais recente e outro para a persistência da variância, evitando a estimação de muitos parâmetros em séries locais com lacunas e observações repetidas. A especificação EGARCH(1,1,1) adiciona apenas um parâmetro de assimetria à estrutura de persistência, permitindo testar respostas diferentes a choques positivos e negativos sem introduzir complexidade excessiva.

O HAR-RV utiliza as janelas de cinco e vinte observações porque elas correspondem aproximadamente às escalas semanal e mensal em uma frequência diária. Os horizontes $h = 1$, $h = 5$ e $h = 20$ representam, respectivamente, previsões de curto prazo, aproximadamente uma semana e aproximadamente um mês de observações. Foi utilizada média condicional zero e distribuição normal das inovações nos modelos GARCH e EGARCH. Essa escolha define um benchmark transparente, concentrado na dinâmica da variância; distribuições com caudas pesadas, como Student- t ou skewed- t , permanecem extensões possíveis de robustez.

Todos os modelos foram reestimados em janelas temporais crescentes, com pelo menos 250 observações de treinamento. A estimação ocorreu separadamente para cada série, horizonte e ano de teste. Os rótulos cujo intervalo futuro alcançava o período de teste foram excluídos do treinamento, evitando que a construção do alvo introduzisse informação futura. Para o EGARCH, as previsões com falhas de convergência ou trajetórias não plausíveis foram excluídas da comparação correspondente, e a análise primária utiliza apenas o suporte temporal comum aos modelos.

A robustez foi avaliada em quatro dimensões. Primeiro, o EGARCH verifica se a assimetria altera a comparação com GARCH e HAR-RV. Segundo, as previsões são avaliadas com QLIKE, MAE e RMSE, sendo QLIKE calculada na escala de variância e MAE e RMSE na escala de volatilidade. Terceiro, a sensibilidade da QLIKE é examinada para diferentes pisos da variância e para uma amostra restrita a alvos positivos, devido à ocorrência de alvos iguais a zero associada a cotações locais inalteradas. Quarto, os resultados são comparados por horizonte, praça, período histórico e regime de volatilidade.

Dessa forma, os modelos econométricos não são utilizados como explicações causais dos preços do café. Eles funcionam como referências estruturadas para medir quanto da volatilidade futura pode ser previsto pelo próprio histórico local e para verificar se a inclusão de variáveis cross-commodity e financeiras produz ganho fora da amostra.

2.6. Modelos de machine learning

Os modelos supervisionados estimam a volatilidade futura a partir dos conjuntos de informação $E1-E4$. A escolha de métodos baseados em árvores decorre da natureza tabular, heterogênea e potencialmente não linear dos atributos, que combinam retornos, medidas de volatilidade, preços de commodities e indicadores financeiros. Esses modelos também permitem representar interações sem impor uma forma funcional linear e não exigem escalonamento das variáveis, o que reduz transformações desnecessárias em uma base com diferentes unidades e frequências de atualização.

O Random Forest foi incluído como referência de agregação por *bagging*. A média de várias árvores reduz a instabilidade de uma árvore individual e oferece uma referência robusta para relações não lineares e observações extremas. O XGBoost foi escolhido como método de *boosting* gradiente, no qual árvores sucessivas corrigem os erros das anteriores e podem capturar interações mais concentradas entre os preditores. O LightGBM amplia essa comparação com uma implementação de *boosting* baseada em histogramas e crescimento eficiente das árvores. A inclusão dos dois métodos de *boosting* permite verificar se o resultado depende de uma implementação específica ou se permanece consistente entre algoritmos com diferentes mecanismos de construção. Em conjunto, os três modelos oferecem um contraste entre redução de variância, aprendizagem sequencial de resíduos e eficiência computacional (Breiman, 2001; Chen and Guestrin, 2016; Ke, Meng, Finley, Wang, Chen, Ma, Ye and Liu, 2017).

Para cada conjunto de informação, horizonte e série-alvo, foi ajustado um modelo independente. Essa organização evita que a distribuição da volatilidade de uma praça seja utilizada para ajustar diretamente outra e permite avaliar se a contribuição dos atributos se mantém nos horizontes de um, cinco e vinte períodos. Os hiperparâmetros foram fixados para controlar a complexidade, preservar a reprodutibilidade e evitar que o número reduzido de observações por série favorecesse árvores excessivamente profundas. No Random Forest, foram utilizados 100 estimadores, profundidade máxima 6 e mínimo de 5 observações por folha. O número de árvores estabiliza a média do ensemble, a profundidade permite interações de ordem moderada e o tamanho mínimo da folha suaviza previsões em regiões com poucas observações.

Nos modelos de *boosting*, foram utilizados 300 estimadores e taxa de aprendizagem 0,05. O número maior de etapas combinado com atualizações pequenas permite construir a previsão gradualmente e reduz a dependência de correções muito agressivas. Para o XGBoost, a profundidade máxima foi 4, enquanto para o LightGBM foi 5. Essa diferença preserva uma complexidade moderada em ambos os casos, considerando suas formas distintas de crescimento. No LightGBM, foi adicionalmente exigido um mínimo de 10 observações por folha, o que reduz a formação de regiões muito específicas. O estado aleatório foi fixado em 42 em todos os modelos. Não foi aplicado escalonamento, pois as decisões das árvores dependem de pontos de corte e não da distância numérica entre as variáveis.

A Figure 3 mostra o fluxo comum dos modelos baseados em árvores. Cada algoritmo recebe os conjuntos de atributos estruturados $E1-E4$ e é estimado de forma independente, de modo que as diferenças de desempenho possam ser atribuídas ao algoritmo ou ao bloco de informação.




Figure 3. Workflow of the tree-based machine learning models for local coffee volatility forecasting.

Para cada conjunto de informação S , horizonte h e algoritmo m , foi estimada uma função

$$\hat{V}_{c,t,h}^{m,S} = \hat{f}_{c,h}^{m,S}(\mathcal{X}_t^S). \quad (22)$$

Foram utilizados três modelos baseados em árvores (Breiman, 2001; Chen and Guestrin, 2016; Ke et al., 2017). O Random Forest combina B árvores de regressão

$$\hat{f}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}), \quad (23)$$

enquanto os modelos de boosting formam uma função aditiva

$$\hat{f}_{Boost}(\mathbf{x}) = \sum_{b=1}^B \eta g_b(\mathbf{x}), \quad (24)$$

em que g_b é uma árvore adicionada sequencialmente e η é a taxa de aprendizagem.

Os valores ausentes dos atributos foram imputados pela mediana do conjunto de treinamento. Para cada variável j , a transformação foi

$$x_{j,t}^{imp} = \begin{cases} x_{j,t}, & \text{se } x_{j,t} \text{ está observado} \\ \text{mediana}(x_{j,t} \mid t \in \mathcal{T}_{train}), & \text{se } x_{j,t} \text{ está ausente.} \end{cases} \quad (25)$$

Os valores de mediana foram recalculados em cada janela e nunca foram estimados com observações do teste. As previsões foram limitadas inferiormente a 10^{-6} para garantir uma quantidade positiva na transformação para variância.

2.7. Validação temporal e prevenção de data leakage

As previsões foram avaliadas por validação temporal com janela de treinamento crescente e reestimação anual. Para um ano de teste y , o ponto de corte é

$$C_y = 1 \text{ de janeiro do ano } y. \quad (26)$$

O conjunto de treinamento para o horizonte h é

$$\mathcal{T}_{y,h} = \{t \mid \text{date}_{c,t} < C_y, \text{ date}_{c,t+h} < C_y, V_{c,t,h} \text{ observado}\}. \quad (27)$$

O conjunto de teste é

$$\mathcal{E}_{y,h} = \{t \mid \text{ano}(\text{date}_{c,t}) = y, V_{c,t,h} \text{ observado}\}. \quad (28)$$

Essa regra elimina do treinamento os rótulos cujo período futuro alcança o ano de teste. A primeira previsão de cada série ocorre depois de pelo menos três anos completos de histórico e cada ajuste exige no mínimo 250 observações válidas. Para o GARCH e o EGARCH, os parâmetros são estimados uma vez por janela anual e mantidos fixos durante o ano de teste. A recursão da variância é atualizada em cada origem com retornos observados até t , sem alterar os parâmetros estimados. Para HAR-RV e para os modelos de machine learning, o ajuste é igualmente realizado somente com as observações do treinamento.

O mesmo princípio temporal foi aplicado à preparação dos dados. A junção temporal, a imputação e o ajuste de cada algoritmo são executados dentro de cada janela. A comparação final utiliza datas comuns a todas as configurações primárias, de modo que uma diferença de desempenho não seja produzida por amostras de teste distintas. A validação comum reúne 12.541 previsões para $h = 1$, 12.529 para $h = 5$ e 12.484 para $h = 20$.

2.8. Métricas de previsão

A qualidade das previsões será comparada entre modelos, conjuntos de informação, séries-alvo e horizontes. A escolha de mais de uma medida é necessária porque a volatilidade futura é avaliada em duas escalas relacionadas, mas não equivalentes. A escala da variância é apropriada para verificar a qualidade da previsão do risco quadrático, enquanto a escala da volatilidade preserva a unidade de interpretação dos retornos acumulados. A tabela resume a função de cada métrica e sua relação com as perguntas empíricas do estudo.

A literatura de avaliação de volatilidade mostra que não existe uma ordenação universal dos modelos independente da função de perda. Hansen e Lunde demonstram que a classificação pode ser inconsistente quando uma proxy inadequada é usada para representar a variância condicional e recomendam avaliações fora da amostra com medidas de volatilidade mais informativas (Hansen and Lunde, 2006). Patton mostra que a comparação pode ser distorcida quando a proxy de volatilidade é imperfeita e identifica uma classe de perdas robustas a esse ruído, na qual a QLIKE ocupa posição central (Patton, 2011). Revisões de previsão de commodities agrícolas também indicam que os resultados dependem do horizonte, da frequência, da especificação do modelo e do protocolo de validação (Guindani et al., 2024). Esses resultados fundamentam o uso conjunto de QLIKE, MAE e RMSE neste estudo.

Para cada previsão, sejam $V_{c,t,h}$ a volatilidade observada, $\hat{V}_{c,t,h}$ a previsão, $Q_{c,t,h} = V_{c,t,h}^2$ a variância observada e $\hat{Q}_{c,t,h} = \hat{V}_{c,t,h}^2$ a variância prevista. A perda QLIKE foi calculada como

Table 2

Forecast evaluation metrics and analytical indicators used in the study

Métrica	Escala e direção	O que privilegia	Questão respondida no estudo
QLIKE	Variância $Q = V^2$, menor é melhor	Avalia a previsão da variância por meio do erro relativo entre Q e $\hat{Q}$. É a medida principal para comparar previsões de risco quadrático.	Qual modelo representa melhor a intensidade do risco futuro quando o alvo é tratado como uma medida de variância e qual informação reduz mais essa perda?
MAE	Volatilidade, menor é melhor	Mede o erro absoluto médio na mesma escala de V . Oferece uma interpretação direta do erro típico e é menos sensível a grandes desvios isolados.	Qual modelo produz previsões mais próximas da volatilidade observada em termos médios e quais resultados permanecem interpretáveis na unidade do fenômeno?
RMSE	Volatilidade, menor é melhor	Eleva ao quadrado os erros antes da média e atribui maior peso a falhas grandes. É especialmente informativa para episódios de estresse e subestimações severas.	Qual modelo reduz melhor os erros extremos e mantém desempenho nos períodos de maior risco?
Ganhos incrementais G_C , G_F e G_{CF}	Redução relativa da perda, maior é melhor	Compara a perda do baseline com a perda após acrescentar informação cross-commodity, financeira ou combinada.	A informação externa acrescenta previsibilidade além do histórico próprio?

$$QLIKE_{c,t,h} = \frac{Q_{c,t,h}}{\hat{Q}_{c,t,h}} - \ln \left(\frac{Q_{c,t,h}}{\hat{Q}_{c,t,h}} \right) - 1. \quad (29)$$

Como existem observações com retorno zero e, consequentemente, $Q_{c,t,h} = 0$, tanto a variância observada quanto a prevista foram limitadas inferiormente por $\epsilon = 10^{-4}$ antes da aplicação da Equação 29. Como a proporção de alvos nulos é elevada, especialmente em $h = 1$, o piso pode dominar o valor da perda nessas observações. Por isso, a ordenação dos modelos pela QLIKE foi reavaliada em dois exercícios de robustez: (i) variando o piso em $\epsilon \in \{10^{-4}, 10^{-2}, 10^{-1}, 1\}$ e (ii) restringindo a avaliação às origens com $Q_{c,t,h} > 0$, nas quais o piso não afeta a variância observada. Os ganhos incrementais também foram recalculados sobre as perdas pooled, isto é, pela razão entre as perdas médias agregadas, o que evita que razões extremas de uma única série dominem a média. A métrica QLIKE é a medida principal para avaliar previsões de variância, enquanto MAE e RMSE são calculados na escala de volatilidade

$$MAE = \frac{1}{n} \sum_{t=1}^n |V_{c,t,h} - \hat{V}_{c,t,h}| \quad (30)$$

e

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (V_{c,t,h} - \hat{V}_{c,t,h})^2}. \quad (31)$$

Para medir a previsibilidade incremental, seja R_S a perda média fora da amostra para o conjunto S . O ganho relativo de adicionar informação cross-commodity, informação financeira e os dois blocos é

$$G_C = \frac{R_{E1} - R_{E2}}{R_{E1}}, \quad G_F = \frac{R_{E1} - R_{E3}}{R_{E1}}, \quad G_{CF} = \frac{R_{E1} - R_{E4}}{R_{E1}}. \quad (32)$$

Também são calculados os ganhos condicionais

$$G_{C|F} = \frac{R_{E3} - R_{E4}}{R_{E3}}, \quad G_{F|C} = \frac{R_{E2} - R_{E4}}{R_{E2}}. \quad (33)$$

Valores positivos indicam redução da perda média e valores negativos indicam piora da previsão após a inclusão do bloco de informação. A interpretação é preditiva e não causal.

As três métricas respondem a dimensões complementares da pergunta de pesquisa. A QLIKE identifica se um modelo estima adequadamente o risco em termos de variância, a MAE mostra a proximidade média na escala de volatilidade e a RMSE revela se o modelo falha principalmente em episódios de grande amplitude. A comparação entre E1 e E2, E3 e E4 verifica se os blocos cross-commodity e financeiro aumentam a previsibilidade além do histórico local. As diferenças entre modelos, horizontes e séries mostram se esses ganhos são estáveis ou dependem da praça e do período analisado. Nenhuma dessas medidas identifica causalidade, pois todas avaliam capacidade preditiva fora da amostra.

2.9. Testes de comparação preditiva

A comparação preditiva verifica se as diferenças observadas nas métricas de previsão são suficientemente grandes para serem distinguidas da variação amostral. A comparação de duas perdas médias pode sugerir que uma configuração é melhor, mas essa diferença pode não se repetir em outras amostras de teste. O teste de Diebold–Mariano avalia a hipótese de igualdade de acurácia preditiva média entre duas configurações, enquanto a correção de Harvey–Leybourne–Newbold ajusta a inferência em amostras finitas e em situações nas quais os erros de previsão apresentam dependência serial (Diebold and Mariano, 1995; Harvey, Leybourne and Newbold, 1997).

Essa correção é particularmente importante neste estudo porque os alvos de cinco e vinte períodos são construídos com retornos futuros sobrepostos. Previsões iniciadas em datas próximas podem compartilhar parte do mesmo intervalo futuro e, por isso, seus diferenciais de perda não são independentes. A estimação da variância com autocovariâncias até $h - 1$ e pesos de Bartlett reduz o risco de declarar superioridade estatística com base em erros-padrão subestimados. Os testes são aplicados separadamente para cada série, horizonte, par de configurações e função de perda, sempre nas datas comuns às previsões comparadas.

Para comparar duas configurações A e B , definem-se os erros de volatilidade

$$e_t^A = V_{c,t,h} - \hat{V}_{c,t,h}^A, \quad e_t^B = V_{c,t,h} - \hat{V}_{c,t,h}^B. \quad (34)$$

Para as perdas de erro quadrático, erro absoluto e QLIKE, a diferença de perdas é, respectivamente,

$$d_t^{SE} = (e_t^A)^2 - (e_t^B)^2, \quad (35)$$

$$d_t^{AE} = |e_t^A| - |e_t^B| \quad (36)$$

e

$$d_t^{QLIKE} = \ell_{A,t}^{QLIKE} - \ell_{B,t}^{QLIKE}. \quad (37)$$

A hipótese nula estabelece igualdade de acurácia preditiva média (Diebold and Mariano, 1995; Harvey et al., 1997). Para acomodar a dependência serial associada a horizontes sobrepostos, a variância da média de d_t foi estimada com autocovariâncias até $h - 1$ e pesos de Bartlett

$$\widehat{\text{Var}}(\bar{d}) = \frac{1}{n} \left[\hat{\gamma}_0 + 2 \sum_{k=1}^{h-1} \left(1 - \frac{k}{h}\right) \hat{\gamma}_k \right], \quad (38)$$

em que

$$\hat{\gamma}_k = \frac{1}{n} \sum_{t=k+1}^n (d_t - \bar{d})(d_{t-k} - \bar{d}). \quad (39)$$

O estatístico de Diebold–Mariano corrigido por Harvey–Leybourne–Newbold é

$$DM_{HLN} = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \sqrt{\frac{n+1-2h+h(h-1)/n}{n}}. \quad (40)$$

Os valores de probabilidade são bicaudais e calculados com distribuição t de Student com $n-1$ graus de liberdade. Os testes são feitos nas datas comuns entre as duas configurações comparadas, para cada série, horizonte, modelo e função de perda.

Como o desenho produz 891 comparações, a significância individual a 5% superestima o número de diferenças genuínas. Por isso, os valores de probabilidade foram também ajustados pelo procedimento de Holm, que controla a taxa de erro familiar, e pelo procedimento de Benjamini–Hochberg, que controla a taxa de falsas descobertas, ambos aplicados ao conjunto completo das 891 comparações (Holm, 1979; Benjamini and Hochberg, 1995). Os testes de QLIKE foram repetidos nas origens com $Q_{c,t,h} > 0$.

Os testes impactam diretamente o objetivo de identificar conteúdo informacional incremental e não apenas diferenças numéricas de desempenho. A comparação entre E1 e E2, E3 e E4 verifica se a inclusão de variáveis cross-commodity, financeiras ou dos dois blocos produz uma redução de perda estatisticamente defensável. As comparações entre GARCH, HAR-RV e os modelos de árvores mostram se uma configuração possui vantagem consistente para uma métrica e um horizonte específicos. A rejeição da hipótese nula indica diferença de acurácia preditiva média, mas não estabelece causalidade nem garante superioridade em períodos ou mercados fora da amostra analisada. Por isso, os valores de probabilidade são interpretados conjuntamente com a magnitude dos ganhos, a função de perda, o horizonte e a heterogeneidade entre as praças.

2.10. Heterogeneidade, explicabilidade e reprodutibilidade

A análise empírica não se limita à comparação da perda média entre modelos. O desempenho pode variar entre períodos de baixa e alta volatilidade, os atributos que sustentam uma previsão precisam ser identificados e todo o procedimento deve permanecer auditável. Por isso, esta seção reúne três análises complementares. A primeira verifica a heterogeneidade do desempenho entre regimes e períodos de estresse. A segunda examina a contribuição relativa das variáveis e dos blocos de informação. A terceira documenta o ambiente computacional e as regras de execução necessárias para reproduzir os resultados. Em conjunto, essas análises conectam a acurácia preditiva à estabilidade, à interpretação econômica e à confiabilidade do pipeline.

2.10.1. Regimes de volatilidade e períodos de estresse

A heterogeneidade do desempenho foi examinada em três regimes de volatilidade. A classificação principal é definida *ex ante*, com base na volatilidade histórica disponível na origem da previsão. Para cada série c e ano de teste y , sejam $\tilde{q}_{33,c,y}$ e $\tilde{q}_{66,c,y}$ os percentis 33,33 e 66,67 de $HVol_{c,s,20}$ calculados somente com as datas $s < C_y$. O regime da origem t é

$$Z_{c,t} = \begin{cases} \text{Low,} & HVol_{c,t,20} \leq \tilde{q}_{33,c,y} \\ \text{Medium,} & \tilde{q}_{33,c,y} < HVol_{c,t,20} \leq \tilde{q}_{66,c,y} \\ \text{High,} & HVol_{c,t,20} > \tilde{q}_{66,c,y}. \end{cases} \quad (41)$$

Essa definição utiliza apenas informação disponível na origem e corresponde ao que um usuário poderia observar ao emitir a previsão. Uma classificação baseada na volatilidade futura observada, isto é, nos tercís de $V_{c,t,h}$, seria condicionada ao próprio desfecho e favoreceria mecanicamente, no tercil alto, os modelos que preveem variâncias elevadas. Essa classificação *ex post* é mantida apenas como decomposição descritiva. Os regimes não são utilizados como atributos e não participam do treinamento.

Para verificar formalmente se o valor da informação externa depende do regime, o diferencial de perdas $d_t = \ell_{E1,t} - \ell_{Ek,t}$, positivo quando o bloco Ek melhora a previsão, foi regredido sobre indicadores dos regimes médio e alto, tendo o regime baixo como referência. O coeficiente do regime alto mede a diferença entre o ganho no regime alto e no regime baixo. Os erros-padrão foram estimados pelo método de Newey–West com $\max(5, h)$ defasagens, para acomodar a dependência serial induzida pela sobreposição dos horizontes e pela baixa frequência de atualização dos preços (Newey and West, 1987). Também foram analisados quatro intervalos históricos, pré-2020, o choque da COVID-19 em 2020, a crise de geadas e oferta entre 2021 e 2022 e a normalização posterior a 2023.

2.10.2. Importância das variáveis e explicabilidade

A análise de explicabilidade foi aplicada aos experimentos E2 e E4 para os três modelos de árvores e para os horizontes $h \in \{1, 5, 20\}$. As importâncias nativas dos modelos de árvores foram registradas para cada atributo e normalizadas dentro de cada ajuste. Para o LightGBM, os valores SHAP foram calculados pelo algoritmo específico para modelos baseados em árvores, que decompõe cada previsão em um valor de referência e contribuições atribuídas aos atributos (Lundberg and Lee, 2017). Para uma observação $\mathbf{x}$, a decomposição é

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j(\mathbf{x}), \quad (42)$$

em que $\phi_j(\mathbf{x})$ representa a contribuição do atributo j para a previsão da observação. A importância global do atributo foi calculada pela média do valor absoluto

$$S_j = \frac{1}{n} \sum_{i=1}^n |\phi_j(\mathbf{x}_i)| \quad (43)$$

e normalizada por

$$\tilde{S}_j = \frac{S_j}{\sum_{\ell=1}^p S_{\ell}}. \quad (44)$$

Os modelos de explicabilidade são ajustados sobre as observações válidas disponíveis para cada série e horizonte, com imputação pela mediana da própria amostra descritiva. Essa análise não substitui a avaliação fora da amostra. Ela tem a finalidade de identificar quais variáveis sustentam a previsão e como a importância se distribui entre histórico próprio, informação cross-commodity e variáveis financeiras.

2.10.3. Implementação e reprodutibilidade

O dataset mestre foi construído em Python 3.12.10. O pipeline utilizou pandas 3.0.5, NumPy 2.5.2, arch 8.0.0, scikit-learn 1.9.0, LightGBM 4.7.0, XGBoost 3.4.1 e shap 0.52.0. A construção do painel, os baselines, os experimentos de machine learning, a validação temporal, os testes estatísticos, a análise de regimes e a explicabilidade foram executados em etapas separadas. As previsões individuais contêm a data de origem, a data final do horizonte, a última data de treinamento, o ponto de corte e a validade da previsão, informações utilizadas para auditar a separação temporal e a cobertura da avaliação.

A leitura conjunta dessas três análises responde perguntas que não podem ser resolvidas por uma métrica agregada. A decomposição por regimes verifica se os ganhos de informação e de algoritmo permanecem durante condições calmas, intermediárias e turbulentas, além de permitir a comparação com períodos históricos de choque. A explicabilidade identifica quais variáveis e blocos sustentam as previsões e ajuda a distinguir um ganho associado ao histórico local de um ganho associado às commodities ou às finanças. A documentação computacional assegura que as escolhas de dados, treinamento, validação e avaliação possam ser auditadas e reproduzidas. Assim, o conjunto complementa a pergunta central sobre previsibilidade incremental com evidências sobre estabilidade, mecanismo informacional e confiabilidade dos resultados. Essas análises permanecem preditivas e não devem ser interpretadas como prova de causalidade.

2.11. Justificativa das escolhas metodológicas

A escolha das séries locais decorre da auditoria de cobertura, densidade e consistência. As demais séries locais de soja, algodão e cacau apresentaram lacunas, unidades variáveis ou baixa frequência incompatíveis com seu uso como variável dependente. Por isso, Arábica e Conilon foram mantidos como alvos e soja, algodão e cacau foram utilizados como sinais cross-commodity. A escolha de uma variedade e um tipo por praça reduz a heterogeneidade causada por diferenças de classificação e unidade dentro da mesma localidade.

O uso de retornos logarítmicos reduz a influência da escala nominal dos preços e produz uma medida comparável entre mercados. A construção de $V_{c,t,h}$ a partir dos próximos retornos observados é adequada às bases disponíveis,

pois não atribui granularidade intradiária a uma base predominantemente diária. A utilização de $h = 1$, $h = 5$ e $h = 20$ permite distinguir previsões de curto prazo, aproximadamente semanais e aproximadamente mensais em dias de observação.

GARCH, EGARCH e HAR-RV formam referências econométricas com diferentes hipóteses sobre persistência, assimetria e agregação temporal. Random Forest, LightGBM e XGBoost ampliam a comparação para relações não lineares e interações entre variáveis sem impor uma forma funcional paramétrica. A comparação E1–E4 foi escolhida para separar o efeito do algoritmo do valor informacional dos blocos de dados.

A validação temporal crescente e a purga dos rótulos que alcançam o ano de teste são necessárias porque a previsão de volatilidade usa observações futuras na construção do alvo. A imputação por janela evita que a disponibilidade posterior de uma variável altere artificialmente o treinamento histórico. QLIKE é mantida como métrica central por avaliar previsões na escala de variância, enquanto MAE e RMSE preservam uma leitura direta do erro na escala de volatilidade.

A classificação *ex ante* por tercís da volatilidade histórica e a análise de períodos históricos mostram se o desempenho muda entre condições calmas e turbulentas usando apenas informação disponível na origem, o que evita o viés de condicionar a avaliação ao próprio desfecho. Por fim, SHAP e as importâncias dos modelos são utilizadas porque um ganho preditivo sem indicação das variáveis responsáveis teria interpretação econômica limitada. Em conjunto, essas escolhas mantêm a análise alinhada ao objetivo de medir previsibilidade incremental em mercados locais integrados a mercados agrícolas e financeiros mais amplos.

3. Experiments and Results

Esta seção descreve a execução empírica do pipeline e apresenta, imediatamente após cada elemento do desenho, os resultados e a discussão correspondentes. O desenho foi organizado para separar três fontes de diferença preditiva. A primeira corresponde à flexibilidade do algoritmo, comparando referências econométricas e modelos de machine learning. A segunda corresponde ao conteúdo informacional, comparando o histórico da própria série com blocos cross-commodity e financeiros. A terceira corresponde à estabilidade da previsão, examinada por horizonte, praça, regime de volatilidade e período de estresse. A unidade experimental é a combinação entre série-alvo, horizonte, data de origem, conjunto de informação e modelo.

A comparação E1–E4 mede se fontes externas acrescentam informação ao histórico local. A comparação entre os algoritmos verifica se relações não lineares produzem vantagem consistente sobre as referências econométricas. Os horizontes, praças e regimes mostram onde essa vantagem permanece ou desaparece. Os testes estatísticos qualificam a magnitude das diferenças e a explicabilidade identifica os blocos associados às previsões.

3.1. Escopo experimental e critérios de comparação

Os experimentos utilizaram o dataset mestre com 14.126 observações de três séries locais. Foram consideradas as séries de café Arábica tipo Rio em Vitória da Conquista e Luís Eduardo Magalhães e de café Conilon tipo 7 em Eunápolis. Para cada série, foram geradas previsões para $h = 1$, $h = 5$ e $h = 20$ observações futuras. Cada previsão foi emitida depois do fechamento observado em t , usando apenas atributos disponíveis até essa origem.

A comparação primária foi formada por GARCH(1,1), HAR-RV, Random Forest, LightGBM e XGBoost. O EGARCH(1,1,1) foi executado como verificação de robustez, mas não foi incluído no suporte comum primário devido a falhas de convergência em parte das janelas. Os modelos de machine learning foram combinados com quatro conjuntos de informação aninhados. E1 contém nove atributos de histórico próprio, E2 contém esses atributos e dez atributos cross-commodity, E3 contém o histórico próprio e onze atributos financeiros e E4 reúne os trinta atributos disponíveis dos três blocos. Essa organização produz doze configurações de machine learning e permite atribuir diferenças de desempenho ao algoritmo ou ao bloco de informação acrescentado. Nas tabelas, o rótulo E0 designa os baselines econométricos GARCH(1,1) e HAR-RV, que utilizam apenas o histórico de retornos da própria série.

Em síntese, o desenho combinou três séries, três horizontes e uma janela expansiva com pelo menos 250 observações de treinamento. Os modelos de machine learning foram estimados com hiperparâmetros fixados, imputação pela mediana calculada no treinamento e semente 42; as configurações primárias foram comparadas somente em datas comuns. O desempenho foi medido por QLIKE, MAE e RMSE, complementado pelos testes DM–HLN, análise por regimes, importâncias dos atributos e SHAP. A robustez foi verificada pelo EGARCH, por diferentes pisos da QLIKE $\epsilon \in \{10^{-4}, 10^{-2}, 10^{-1}, 1\}$ e pela avaliação restrita às observações com alvo positivo. Os detalhes de estimação, validação temporal e controle de data leakage são apresentados nas subseções seguintes.

3.2. Estimação dos modelos e configuração computacional

O GARCH(1,1) foi ajustado aos retornos da série-alvo em cada janela anual e suas previsões foram atualizadas recursivamente com os retornos observados até a origem. O HAR-RV foi estimado por mínimos quadrados usando o retorno absoluto diário e medidas históricas em janelas de cinco e vinte observações. O EGARCH seguiu a mesma separação temporal e utilizou 1.000 simulações nos horizontes superiores a um período. Seus parâmetros permaneceram fixos durante cada ano de teste.

Os modelos tabulares foram ajustados separadamente para cada combinação de série, horizonte, conjunto de informação e janela anual. O Random Forest utilizou 100 árvores, profundidade máxima igual a 6 e mínimo de cinco observações por folha. O LightGBM utilizou 300 árvores, profundidade máxima igual a 5, taxa de aprendizagem de 0,05 e mínimo de dez observações por folha. O XGBoost utilizou 300 árvores, profundidade máxima igual a 4 e taxa de aprendizagem de 0,05. Todos os algoritmos utilizaram `random_state=42` e uma única unidade de processamento. Não foi realizada otimização de hiperparâmetros nessa etapa. A fixação dos valores mantém constante a complexidade dos modelos e concentra a comparação no efeito do algoritmo e dos conjuntos de informação.

Antes do ajuste, os atributos ausentes foram imputados pela mediana calculada exclusivamente no conjunto de treinamento. A mesma transformação foi aplicada ao conjunto de teste sem recalculer a mediana. As previsões de volatilidade foram limitadas inferiormente por 10^{-6} , enquanto o piso $\epsilon = 10^{-4}$ foi aplicado às variâncias na perda QLIKE. Esses controles evitam previsões negativas e problemas numéricos associados a janelas com retornos iguais a zero.

3.3. Validação temporal, controle de data leakage e cobertura da avaliação

O protocolo utilizou uma janela de treinamento crescente e um ciclo de teste anual. A primeira janela foi formada após três anos de observações disponíveis e cada ajuste exigiu pelo menos 250 observações válidas. Em cada ano, todos os atributos, imputações e parâmetros supervisionados foram definidos dentro da janela de treinamento. O conjunto de teste permaneceu separado até a geração da previsão.

Como o alvo de horizonte h utiliza retornos posteriores à origem, o treinamento foi purgado quando a última observação necessária para construir o rótulo alcançava o ano de teste. A auditoria registrou 186 combinações de série, horizonte e ano de teste e removeu 1.578 rótulos potencialmente sobrepostos ao período de avaliação. As previsões individuais conservaram a origem, o final do horizonte, a última data de treinamento, o ponto de corte e o indicador de validade. Essas informações permitiram verificar que nenhum rótulo supervisionado utilizou observações posteriores ao corte.

Foram tentadas 37.554 previsões para cada configuração, somando as três séries e os três horizontes. As configurações primárias apresentaram 100% de previsões válidas. O EGARCH apresentou 95,26% de validade agregada, devido a limitações de convergência, e foi mantido fora da comparação primária por essa razão. Para a comparação principal, foram mantidas somente as datas nas quais todas as configurações primárias possuíam previsão válida. O suporte comum reuniu 12.541 datas para $h = 1$, 12.529 para $h = 5$ e 12.484 para $h = 20$, garantindo que as diferenças de erro não fossem produzidas por amostras distintas.

3.4. Desempenho pooled: baselines vs. machine learning

A avaliação combinou a perda orientada à variância (QLIKE) com medidas de erro na escala de volatilidade (MAE e RMSE). A Table 3 mostra uma separação sistemática entre essas perspectivas: o GARCH(1,1) lidera a QLIKE nos três horizontes, enquanto o HAR-RV lidera simultaneamente MAE e RMSE. O resultado não representa uma contradição entre as métricas; ele indica que os baselines capturam propriedades diferentes do alvo. A especificação GARCH é mais adequada quando a comparação privilegia a coerência da variância condicional, ao passo que a estrutura HAR-RV, ao incorporar persistência em diferentes escalas temporais, produz previsões mais próximas da volatilidade observada em termos absolutos e nos erros de maior amplitude. Portanto, a escolha do vencedor depende da pergunta preditiva e não deve ser reduzida a uma única ordenação de modelos.

Entre os modelos de machine learning, o Random Forest foi o competidor mais consistente, sobretudo por manter desempenho relativamente estável quando o conjunto de informação e o horizonte variam. Ainda assim, sua melhor configuração não superou o HAR-RV nas métricas de escala de volatilidade e permaneceu atrás do GARCH na QLIKE. A aproximação observada no horizonte longo sugere que atributos externos podem contribuir quando o sinal de curtíssimo prazo perde força, mas não é suficiente para alterar a conclusão pooled. Em outras palavras, a flexibilidade das árvores encontrou padrões úteis em alguns cenários, porém esses ganhos foram locais e não se converteram em vantagem agregada sobre os baselines.

Table 3

Pooled winning configurations by horizon and loss

h	Perda	Configuração vencedora	Valor
1	QLIKE	E0-GARCH(1,1)	9,374
1	MAE	E0-HAR-RV	1,074
1	RMSE	E0-HAR-RV	2,442
5	QLIKE	E0-GARCH(1,1)	6,362
5	MAE	E0-HAR-RV	2,783
5	RMSE	E0-HAR-RV	4,992
20	QLIKE	E0-GARCH(1,1)	2,606
20	MAE	E0-HAR-RV	5,254
20	RMSE	E0-HAR-RV	8,697

Os modelos de boosting apresentaram maior instabilidade sob QLIKE, com sensibilidade mais acentuada à combinação entre horizonte, praça e conjunto de atributos. Esse padrão recomenda cautela com a interpretação de uma configuração isolada como evidência de superioridade. A comparação pooled sustenta uma conclusão mais restrita: modelos não lineares podem complementar a modelagem econométrica, mas a flexibilidade não paramétrica, isoladamente, não substitui uma referência adequada à escala do risco. Como a agregação dá o mesmo peso a cada previsão individual, ela resume o desempenho global e pode ocultar ganhos ou perdas específicos de uma praça; por isso, a decomposição por série e horizonte é apresentada na sequência.

A Figure 4 representa graficamente essa comparação pooled, mostrando QLIKE (em escala logarítmica), MAE e RMSE por horizonte para os dois baselines e a melhor configuração de cada família de machine learning. A figura evidencia visualmente a inversão de ordenação entre QLIKE e as métricas de escala de volatilidade e a maior dispersão de LightGBM e XGBoost sob QLIKE.




Figure 4. Pooled QLIKE, MAE and RMSE by horizon for GARCH(1,1), HAR-RV and the best configuration of each machine-learning family.

3.5. Robustez da QLIKE aos alvos nulos

Como a volatilidade futura é nula em grande parte das origens, especialmente em $h = 1$, os valores absolutos da QLIKE pooled são elevados e dependem do piso ϵ . Para verificar se a ordenação dos modelos é um artefato desse piso, a Table 4 representa a QLIKE pooled com $\epsilon = 1$ e restrita às origens com $Q_{c,t,h} > 0$.

O GARCH(1,1) apresentou a menor QLIKE pooled em todos os cenários e horizontes, inclusive nos valores intermediários $\epsilon = 10^{-2}$ e $\epsilon = 10^{-1}$, não reportados na tabela. A magnitude das perdas diminui à medida que o

Table 4

QLIKE robustness: pooled QLIKE of GARCH(1,1), HAR-RV and the best machine-learning configuration under alternative variance floors and on non-zero targets

Cenário	h	n	GARCH	HAR-RV	Melhor ML	Configuração
$\epsilon = 10^{-4}$	1	12.541	9,374	49,990	20,437	E2-RF
	5	12.529	6,362	7,636	7,754	E2-RF
	20	12.484	2,606	2,688	3,373	E1-RF
$\epsilon = 1$	1	12.541	1,956	5,382	3,950	E4-XGB
	5	12.529	2,332	3,658	3,781	E2-RF
	20	12.484	1,888	1,970	2,656	E1-RF
$Q > 0$	1	2.131	7,810	258,759	84,806	E2-RF
	5	7.033	2,518	5,629	5,846	E2-RF
	20	11.525	1,765	1,879	2,638	E1-RF

piso aumenta ou que os alvos nulos são excluídos, mas a ordenação entre GARCH, HAR-RV e o melhor modelo de machine learning permanece inalterada. Nas origens com variação de preço, o GARCH também apresentou o menor MAE e o menor RMSE em $h = 1$, com 2,305 e 5,002, enquanto o HAR-RV manteve as menores perdas de escala de volatilidade em $h = 5$ e $h = 20$. Esse resultado indica que parte da vantagem do HAR-RV em MAE no horizonte curto decorre de previsões baixas nas origens sem variação de preço. Os testes DM-HLN de QLIKE restritos às origens com $Q_{c,t,h} > 0$ confirmam o padrão: nenhuma configuração de machine learning foi significativamente superior ao GARCH ou ao HAR-RV, e 66 das 108 comparações com o GARCH foram significativamente favoráveis ao GARCH. Portanto, a vantagem do GARCH em QLIKE não é um artefato do tratamento dos alvos nulos.

3.6. Resultados por praça e horizonte

A decomposição por série confirma a heterogeneidade observada no EDA e responde ao objetivo de verificar se a previsibilidade se mantém entre localidades. O GARCH apresentou a menor QLIKE em oito das nove combinações de série e horizonte. A exceção ocorreu em Luís Eduardo Magalhães no horizonte de vinte observações, em que o HAR-RV apresentou QLIKE de 2,488, inferior ao GARCH. O HAR-RV apresentou o menor RMSE nas nove combinações e o menor MAE em oito. A exceção de MAE também ocorreu em Luís Eduardo Magalhães em $h = 20$, quando E2 com Random Forest apresentou MAE de 6,665, contra 6,682 do HAR-RV.

A vantagem das referências econométricas foi mais clara nos horizontes curtos e intermediários para QLIKE. No horizonte longo, a proximidade entre as previsões aumentou em algumas praças e a informação cross-commodity tornou-se competitiva para o Random Forest. Em Luís Eduardo Magalhães, E2 com Random Forest apresentou MAE de 6,665 e RMSE de 9,203 em $h = 20$. Em Vitória da Conquista e Eunápolis, entretanto, o HAR-RV manteve as menores perdas de escala de volatilidade. A diferença entre as praças reforça que a utilidade dos atributos externos não é homogênea e deve ser avaliada por série e horizonte.

3.7. Valor incremental dos blocos de informação

As comparações incrementais foram calculadas tomando E1 como referência para cada série, horizonte e algoritmo, de modo que o ganho de E2, E3 ou E4 representasse a redução relativa da perda associada ao novo bloco de informação. A comparação E1–E4 foi realizada conforme o desenho experimental e tomou E1 como referência dentro de cada algoritmo, série e horizonte. A informação cross-commodity foi o bloco externo mais consistente para o Random Forest. Como mostra a Table 5, E2 reduziu a QLIKE do Random Forest em todas as três séries para $h = 1$, em duas séries para $h = 5$ e em apenas uma série para $h = 20$. Na escala de volatilidade, E2 melhorou o MAE em uma série no horizonte curto, em uma no horizonte intermediário e em duas no horizonte longo. O RMSE foi reduzido em duas séries no horizonte curto, em uma no horizonte intermediário e nas três séries no horizonte longo.

Os ganhos médios de E2 para o Random Forest foram de 5,30% em QLIKE no horizonte curto, 2,85% no horizonte intermediário e -2,82% no horizonte longo. Para MAE, os ganhos médios foram -0,89%, -0,71% e 1,22%. Para RMSE, foram 0,35%, -1,00% e 3,15%. Esses valores evidenciam que o acréscimo de commodities relacionadas pode melhorar a previsão em determinados mercados, mas não produz ganho uniforme em todas as métricas.

O bloco financeiro não apresentou uma melhoria sistemática em relação ao histórico próprio. Para o Random Forest, os ganhos médios de E3 foram negativos em QLIKE nos três horizontes e também em MAE e RMSE. O conjunto completo E4 reproduziu esse padrão, com ganhos médios negativos para o Random Forest nas três métricas.

Os resultados de LightGBM e XGBoost mostram que a instabilidade sob QLIKE é mais intensa nos modelos de boosting. A média simples de ganhos relativos por série, utilizada acima para o Random Forest, torna-se pouco

Table 5

Incremental gains from cross-commodity information for Random Forest

Série	h	QLIKE (%)	MAE (%)	RMSE (%)
Arábica LEM	1	3,94	-1,02	-0,20
Arábica LEM	5	8,75	3,22	2,39
Arábica LEM	20	2,96	4,28	4,57
Arábica VDC	1	5,57	1,70	1,08
Arábica VDC	5	1,66	-2,88	-4,10
Arábica VDC	20	-8,41	0,90	3,20
Conilon Eunápolis	1	6,40	-3,34	0,18
Conilon Eunápolis	5	-1,86	-2,48	-1,30
Conilon Eunápolis	20	-3,02	-1,51	1,68

Table 6Incremental gains (%) over E1 computed on pooled losses, by model, information block and horizon ($\epsilon = 10^{-4}$)

Modelo	Bloco	QLIKE			MAE			RMSE		
		$h = 1$	$h = 5$	$h = 20$	$h = 1$	$h = 5$	$h = 20$	$h = 1$	$h = 5$	$h = 20$
Random Forest	E2	5,59	2,42	-4,20	-0,63	-0,59	1,43	0,47	-1,33	3,29
Random Forest	E3	-3,42	-9,77	-8,20	-7,46	-8,78	-15,08	-4,04	-10,04	-19,66
Random Forest	E4	0,01	-6,60	-5,64	-5,78	-5,32	-16,73	-2,51	-8,28	-19,50
LightGBM	E2	-39,13	29,01	-660,67	-3,01	-3,16	3,50	-1,74	-4,43	5,37
LightGBM	E3	-179,37	-138,98	60,30	-4,77	-17,54	-7,16	-3,33	-17,82	-12,28
LightGBM	E4	-151,52	-6,77	-39,47	-4,68	-12,12	-6,01	-2,70	-14,24	-9,82
XGBoost	E2	72,21	91,53	-649,28	5,76	0,65	1,40	20,43	1,84	6,24
XGBoost	E3	73,16	44,42	-47,13	-6,18	-13,14	-10,84	21,73	-9,36	-9,75
XGBoost	E4	64,21	28,61	-861,13	-2,66	-9,07	-12,40	24,20	-5,63	-10,71

informativa para esses modelos, pois uma única série com perda explosiva domina a média. Por isso, a Table 6 apresenta os ganhos calculados sobre as perdas pooled, isto é, $1 - \bar{R}_{Ek} / \bar{R}_{E1}$, em que $\bar{R}$ é a perda média agregada das três séries.

Três padrões emergem. Primeiro, para o Random Forest, o bloco cross-commodity produz ganhos pequenos e de sinal variável, positivos em QLIKE nos horizontes curto e intermediário e em MAE e RMSE no horizonte longo. Segundo, os blocos financeiro e completo pioram o MAE e o RMSE em todos os modelos no horizonte de vinte observações, com perdas entre 6% e 20%. Terceiro, os ganhos de QLIKE dos modelos de boosting alternam valores positivos elevados e perdas de várias centenas de por cento. Os ganhos positivos do XGBoost em $h = 1$ e $h = 5$ refletem sobretudo a fragilidade da configuração E1 desse modelo, e não um bom desempenho absoluto, pois nenhuma configuração do XGBoost se aproxima das perdas do GARCH ou do HAR-RV. Restringindo a avaliação às origens com $Q_{c,t,h} > 0$, os padrões se mantêm: o ganho de QLIKE do Random Forest com E2 é de 7,90%, 5,46% e -5,86% nos três horizontes, e os blocos E3 e E4 permanecem negativos em $h = 5$ e $h = 20$. Portanto, apenas o bloco cross-commodity no Random Forest produz ganhos de magnitude estável, ainda que pequenos, e a informação financeira não se traduz em ganho preditivo.

A Figure 5 resume os ganhos do Random Forest por bloco de informação e horizonte, calculados sobre as perdas pooled. O Random Forest é o único modelo cujos ganhos de QLIKE permanecem em uma escala interpretável nos três blocos. O bloco cross-commodity (E2) é o único que preserva ganho médio positivo em QLIKE nos horizontes curto e intermediário, enquanto os blocos financeiro (E3) e completo (E4) produzem perdas médias em praticamente todas as combinações de métrica e horizonte, confirmando que informação adicional não implica necessariamente ganho preditivo.




Figure 5. Incremental gains of Random Forest over the E1 own-history baseline, computed on pooled losses, by information block (E2, E3, E4) and horizon.

3.8. Comparações de superioridade preditiva (testes DM-HLN)

As diferenças de desempenho foram submetidas ao teste Diebold-Mariano com a correção de Harvey, Leybourne e Newbold. Foram avaliadas as perdas ao quadrado, as perdas absolutas e a QLIKE. O primeiro conjunto de comparações examinou E1 contra E2, E3 e E4 dentro de cada família de machine learning. O segundo comparou cada configuração de machine learning com HAR-RV e GARCH(1,1). A direção do diferencial foi mantida junto ao valor de probabilidade para distinguir melhoria, empate estatístico e deterioração.

A análise dos testes DM-HLN reuniu 891 comparações sobre o mesmo suporte temporal utilizado na avaliação: 243 comparações entre E1 e os blocos ampliados dentro das famílias de machine learning e 648 comparações entre cada configuração de machine learning e os baselines GARCH(1,1) e HAR-RV. Cada comparação foi definida por série, horizonte, par de modelos e função de perda, e os resultados agregados são apresentados na Table 7. Dentro das famílias de machine learning, as diferenças entre E1 e os blocos ampliados foram significativas em 54 de 81 comparações de MAE, 53 de 81 comparações de erro quadrático e 10 de 81 comparações de QLIKE. Contudo, somente 13 comparações de MAE e oito de erro quadrático foram significativamente favoráveis ao conjunto ampliado. Nenhuma diferença de QLIKE significativa favoreceu E2, E3 ou E4. Assim, a evidência estatística apoia ganhos incrementais localizados, mas não uma superioridade geral da informação externa.

As comparações com os baselines reforçam a dependência da função de perda. Em QLIKE, nenhuma configuração de machine learning foi significativamente superior ao GARCH ou ao HAR-RV. Em MAE, 88 das 108 comparações entre machine learning e GARCH foram significativamente favoráveis ao modelo de machine learning, enquanto nenhuma comparação com o HAR-RV foi significativamente favorável ao machine learning. Em erro quadrático, 40 comparações foram significativamente favoráveis ao machine learning contra o GARCH e nenhuma contra o HAR-RV. Portanto, os modelos de machine learning conseguem superar o GARCH em parte das comparações na escala de volatilidade, mas não superam o HAR-RV de forma estatisticamente significativa nessa escala.

A Table 7 consolida essas 891 comparações DM-HLN em contagens por tipo de comparação e função de perda, com e sem correção para múltiplas comparações.

Nas três primeiras linhas, “Fav.” conta comparações significativas a favor do conjunto de informação ampliado (E2, E3 ou E4) sobre E1. Nas demais linhas, conta comparações significativas a favor do modelo de machine learning sobre o baseline econométrico correspondente. As diferenças significativas não favoráveis correspondem a deteriorações.

A correção para múltiplas comparações reduz substancialmente a evidência a favor da informação externa. Sob o critério de Holm, que controla a probabilidade de ao menos um falso positivo entre as 891 comparações, restam apenas duas comparações de MAE e três de erro quadrático significativamente favoráveis aos conjuntos ampliados, contra 28 e 19 comparações significativamente desfavoráveis. Sob o critério de Benjamini–Hochberg, menos conservador, restam

Table 7

DM-HLN test outcomes by comparison type and loss function: raw 5% significance and after Benjamini–Hochberg (BH) and Holm corrections over the 891 tests

Comparação	Perda	N	5%		BH		Holm	
			Sig.	Fav.	Sig.	Fav.	Sig.	Fav.
E1 vs. E2/E3/E4	MAE	81	54	13	49	11	30	2
E1 vs. E2/E3/E4	RMSE	81	53	8	46	6	22	3
E1 vs. E2/E3/E4	QLIKE	81	10	0	9	0	0	0
ML vs. GARCH(1,1)	MAE	108	94	88	93	87	77	73
ML vs. GARCH(1,1)	RMSE	108	68	40	60	40	39	32
ML vs. GARCH(1,1)	QLIKE	108	65	0	59	0	16	0
ML vs. HAR-RV	MAE	108	94	0	87	0	69	0
ML vs. HAR-RV	RMSE	108	99	0	96	0	48	0
ML vs. HAR-RV	QLIKE	108	43	0	37	0	11	0

11 e 6 comparações favoráveis. Em contraste, a superioridade do HAR-RV sobre os modelos de machine learning e a vantagem do GARCH em QLIKE permanecem após as duas correções. Para o Random Forest com E2, as comparações significativamente favoráveis a 5% foram 3 de 9 em MAE, 1 de 9 em erro quadrático e nenhuma em QLIKE.

3.9. Regimes de volatilidade e períodos de estresse

A heterogeneidade foi examinada com regimes definidos *ex ante* pelos tercís da volatilidade histórica $HVol_{c,t,20}$, com limiares estimados apenas com dados anteriores a cada ano de teste (Equação 41). O regime baixo concentra 5.730 origens por horizonte, e os regimes médio e alto concentram cerca de 3.500 e 3.300 origens, respectivamente. A assimetria decorre da redução da volatilidade histórica nos anos mais recentes em relação aos limiares estimados com o histórico anterior.

A ordenação entre os modelos permaneceu estável entre os regimes. O GARCH apresentou a menor QLIKE pooled nos três regimes, com 6,336, 5,997 e 5,871 nos regimes baixo, médio e alto, e também nas origens com variação de preço, com 2,426, 2,691 e 2,910. O melhor modelo de machine learning, sempre uma configuração do Random Forest, registrou QLIKE entre 9,799 e 10,722. Em MAE, o HAR-RV foi a melhor referência nos três regimes, com 2,823, 2,908 e 3,535, praticamente empatado com o Random Forest com E2 no regime baixo, com 2,826. Portanto, a vantagem das referências econométricas não depende do regime.

O valor da informação externa, por outro lado, depende fortemente do regime. A Figure 6 apresenta o ganho de MAE de cada bloco sobre E1, calculado sobre as perdas pooled em cada regime. No regime baixo, os blocos financeiro e completo pioram o MAE em 20% a 27% em todos os modelos. No regime médio, as perdas diminuem para 2% a 8%. No regime alto, os ganhos tornam-se positivos, entre 1,8% e 7,6% para E3 e entre 0,7% e 7,4% para E4. O bloco cross-commodity, ao contrário, apresenta ganhos pequenos e aproximadamente estáveis entre os regimes, entre -1,7% e 2,5%.




Figure 6. MAE gain over the E1 own-history baseline by ex-ante volatility regime (terciles of trailing $HVol_{20}$, thresholds estimated before each test year), by information block and model. Gains are computed on pooled losses.

Os testes HAC confirmam esse padrão. Para os blocos financeiro e completo, a diferença entre o ganho no regime alto e no regime baixo foi positiva e significativa a 5% em 6 a 7 das 9 combinações de série e horizonte em MAE para cada modelo, e em 3 a 5 das 9 em erro quadrático, com no máximo uma diferença significativa em sentido contrário. Para o bloco cross-commodity, as diferenças significativas foram raras e de sinais opostos, entre uma e três por modelo e perda. Em QLIKE restrita às origens com variação de preço, quase nenhuma diferença entre regimes foi significativa.

Esse resultado indica que as variáveis financeiras não são inúteis em todas as condições. Elas pioram a previsão em períodos calmos, quando a volatilidade local é baixa e as variações dos mercados financeiros não se transmitem às cotações locais, e passam a acrescentar informação em períodos de volatilidade elevada. Como os regimes calmos predominam na amostra, o efeito médio é negativo. A decomposição *ex post*, baseada nos tercís da volatilidade futura, sugeria o padrão oposto, com ganhos do bloco cross-commodity concentrados no regime alto e ganhos financeiros negativos em todos os regimes. Essa divergência ilustra o viés de condicionar a avaliação ao desfecho e justifica o uso da classificação *ex ante* como análise principal.

A decomposição por períodos históricos produziu padrão consistente com a estabilidade das referências. O GARCH apresentou a menor QLIKE média antes de 2020, durante o choque da COVID-19, durante a crise de geada e oferta de 2021–2022 e no período posterior a 2023, com médias de 6,73, 4,54, 4,96 e 4,42. A análise por período não estabelece causalidade para os eventos, mas identifica a mudança de dificuldade preditiva ao longo do tempo.

3.10. Importância das variáveis e interpretação dos resultados

A análise de importância foi utilizada para interpretar quais blocos sustentam as previsões dos modelos de árvore, e não para substituir a avaliação fora da amostra. A Figure 7 mostra dois padrões. No conjunto E2, o histórico próprio e as variáveis cross-commodity mantêm participações próximas nos três horizontes. No conjunto E4, a participação financeira aumenta com o horizonte e se torna dominante em $h = 20$, enquanto a contribuição relativa do histórico próprio diminui. Assim, a composição da previsão se desloca do sinal local e das commodities para variáveis financeiras quando o horizonte se alonga.




Figure 7. Mean feature-group importance by horizon for the E2 and E4 information sets, averaged across varieties and tree-based models.

Entre os atributos individuais, `return_lag4` e `cepea_return` apareceram entre os mais importantes em $h = 1$ no conjunto E2. Em $h = 5$ e $h = 20$, `hist_vol_20` permaneceu entre os principais atributos em E2. Em E4, `selic` foi o atributo de maior importância média nos horizontes de cinco e vinte observações. Essas importâncias são diagnósticos de contribuição relativa dentro dos modelos e não representam elasticidades ou efeitos causais.

Os valores SHAP do LightGBM reforçam essa mudança de composição. Em E4, as variáveis financeiras concentram a maior parte da contribuição no horizonte longo, enquanto o histórico próprio e as commodities têm papel relativamente maior nos horizontes curtos. Os atributos mais associados às previsões ampliadas são níveis de juros, como Selic, Fed Funds e Treasury, nos horizontes de cinco e vinte observações; em E2, o retorno do CEPEA e a volatilidade histórica aparecem como referências mais importantes. O padrão é coerente com a ideia de que o horizonte mais longo favorece sinais financeiros persistentes, mas não demonstra que esses sinais gerem previsões mais precisas.

A distinção entre importância e desempenho é central. Os níveis de juros podem funcionar como marcadores do período amostral, especialmente em árvores ajustadas com janela crescente, e por isso apresentar elevada contribuição dentro da amostra sem produzir ganho fora da amostra em E3 e E4 (Table 6). Do mesmo modo, a importância de uma variável não deve ser interpretada como elasticidade, efeito causal ou evidência de transmissão de risco. A explicabilidade identifica associação com a previsão; a utilidade preditiva continua sendo determinada pelas perdas e pelos testes fora da amostra.

A Figure 8 mostra que essa composição não é igual entre as variedades. No Arábica, o bloco financeiro ganha predominância a partir do horizonte intermediário; no Conilon, essa predominância aparece apenas no horizonte longo, enquanto a contribuição cross-commodity diminui progressivamente. A diferença recomenda evitar uma leitura única para o café local: os atributos relevantes dependem da variedade, do horizonte e da estrutura de transmissão de cada praça. Como as importâncias são normalizadas dentro de cada ajuste, a comparação deve ser entendida como diferença de composição relativa, e não como diferença de efeito causal ou de magnitude absoluta.




Figure 8. Mean feature-group importance by horizon for the E4 information set, disaggregated by coffee variety (Arabica vs. Conilon).

3.11. Síntese dos resultados

Os resultados consolidam uma resposta qualificada ao objetivo central do estudo. A ampliação do conjunto de variáveis não produziu uma melhoria sistemática sobre o histórico local, e a maior flexibilidade algorítmica também não garantiu superioridade fora da amostra. Isso não significa que as informações externas sejam irrelevantes; significa que seu valor depende da métrica de risco, do horizonte, do regime de volatilidade e da variedade analisada.

Para a primeira pergunta de pesquisa, a principal conclusão é que não existe um vencedor universal. O GARCH é a referência mais adequada quando a previsão é avaliada na escala da variância, enquanto o HAR-RV é mais consistente na aproximação da volatilidade observada. Essa complementaridade muda a interpretação da comparação com machine learning: a questão não é apenas se um algoritmo é mais flexível, mas se sua função de estimação está alinhada ao tipo de erro que o usuário pretende controlar.

As perguntas sobre informação externa também foram respondidas de maneira condicional. O bloco cross-commodity oferece sinais complementares, mas não altera a hierarquia global dos modelos. O bloco financeiro apresenta maior associação com as previsões em horizontes longos, porém sua importância dentro dos modelos não se converte automaticamente em acurácia fora da amostra. O resultado mais relevante é a dependência do regime: sinais financeiros podem ser úteis em períodos de maior tensão e contraproducentes em condições calmas. Portanto, a informação externa deve ser tratada como recurso dependente do estado do mercado, e não como um acréscimo universal ao conjunto de atributos.

Outro resultado consolidado diz respeito à unidade de informação do problema. As cotações locais são pouco frequentes, apresentam atualizações irregulares e geram muitos alvos sem variação. Nessa estrutura, parte importante da previsibilidade está relacionada ao processo de atualização dos preços, e não apenas a relações não lineares entre mercados. Esse achado ajuda a explicar por que modelos econométricos simples, apoiados na persistência local, permanecem competitivos e por que a complexidade dos modelos de machine learning não se traduz automaticamente em ganho.

A análise de importância acrescenta ainda que os fatores associados às previsões não são intercambiáveis entre Arábica e Conilon. A composição informacional muda entre variedades e horizontes, o que limita a transferência direta de uma estratégia de atributos de uma praça para outra. Ao mesmo tempo, a diferença entre importância e desempenho mostra que explicabilidade deve ser usada para formular hipóteses sobre o mecanismo preditivo, enquanto a decisão de seleção do modelo deve continuar baseada na avaliação fora da amostra.

Em conjunto, o estudo atinge seu objetivo ao distinguir três situações que uma comparação simples de algoritmos ocultaria: referências econométricas dominantes na avaliação global, ganhos externos localizados e valor financeiro dependente do regime. Essa síntese desloca a discussão de qual modelo é mais complexo para quando a informação adicional é confiável, qual perda deve orientar a escolha e como a frequência de atualização dos preços condiciona a previsibilidade. A seção seguinte interpreta esses mecanismos à luz da literatura, discute suas implicações para os mercados locais de café e delimita o alcance dos resultados.

O experimento foi executado em Python 3.12.10, com pandas 3.0.5, NumPy 2.5.2, arch 8.0.0, scikit-learn 1.9.0, LightGBM 4.7.0, XGBoost 3.4.1 e shap 0.52.0. Os códigos-fonte utilizados na coleta, construção do painel, estimação, validação temporal, testes estatísticos, análises de robustez e geração das figuras foram mantidos abertos para consulta e reprodução em repositório público, com o link e o DOI indicados na versão final. Os parâmetros, sementes, critérios de retenção e regras de avaliação estão descritos nas subseções metodológicas, e as análises de robustez utilizam as mesmas previsões fora da amostra, sem reestimação dos modelos.

4. Discussion

O achado central deste estudo é que, em mercados locais de café com cotações pouco frequentes e atualizações irregulares, ampliar o conjunto de variáveis e utilizar algoritmos mais flexíveis não produz, por si só, melhoria sistemática da previsão fora da amostra. As referências econométricas permanecem competitivas, mas não existe um vencedor universal: o GARCH é mais adequado quando a avaliação privilegia a variância, enquanto o HAR-RV é mais consistente na escala da volatilidade. A informação cross-commodity acrescenta sinais localizados, e a informação financeira apresenta valor dependente do regime, com importância elevada dentro dos modelos sem correspondente ganho preditivo geral.

Em bases dominadas por contratos futuros, índices ou cotações de alta frequência, a ampliação do conjunto de preditores costuma ser avaliada sobre observações regulares e alvos continuamente variáveis. Nas séries locais analisadas aqui, a estrutura é diferente: muitas cotações permanecem inalteradas e vários horizontes começam com variação futura nula. Nessa situação, o histórico próprio já contém a persistência dominante; a inclusão de variáveis financeiras aumenta sua importância dentro das árvores, mas não reduz de forma correspondente as perdas fora da amostra. A diferença entre contribuição para o ajuste e redução efetiva do erro impede tratar uma variável importante como automaticamente preditiva.

Essa evidência estabelece uma regra de seleção dependente do uso. Quando o interesse é representar a variância condicional, o GARCH fornece a referência; quando o objetivo é aproximar a magnitude observada da volatilidade, o HAR-RV ocupa essa posição. Os atributos externos só acrescentam informação em condições específicas de volatilidade e sua composição muda entre Arábica e Conilon. Assim, os modelos de machine learning funcionam como extensões condicionais dos baselines, enquanto a integração entre mercados deve ser testada por horizonte, regime e variedade, e não presumida a partir da disponibilidade de mais variáveis. Essa leitura orienta a discussão dos mecanismos preditivos, das implicações para os agentes e dos limites de generalização, sem atribuir causalidade aos resultados.

4.1. Por que as referências econométricas permanecem difíceis de superar

A principal conclusão do estudo é que modelos econométricos simples, estimados apenas com o histórico local, não foram superados por modelos de machine learning mais flexíveis nem por conjuntos de informação mais amplos. Esse resultado contrasta com estudos que reportam ganhos de modelos híbridos e de aprendizagem de máquina na previsão de volatilidade e preços agrícolas (Manogna et al., 2025; Zhang et al., 2025; Jin and Xu, 2024), mas é consistente com revisões que mostram que os ganhos desses modelos dependem do mercado, da frequência dos dados, do horizonte e do protocolo de validação (Guindani et al., 2024). Três características do presente desenho ajudam a explicar a diferença.

A primeira é a natureza das séries. As cotações locais da SEAGRI-BA permanecem inalteradas em 77% a 88% das datas, e a volatilidade futura é nula na maior parte das origens de curto prazo. Nessas condições, a dinâmica relevante assemelha-se a uma sequência de saltos esparsos, e não a um processo contínuo com interações não lineares ricas. A vantagem de modelos flexíveis depende da existência de padrões complexos e estáveis que o histórico próprio não capture, o que é pouco provável em séries com essa densidade de informação.

A segunda é o alinhamento entre a função de estimação e a função de avaliação. O GARCH é estimado por quase-máxima verossimilhança gaussiana, cuja perda implícita coincide com a QLIKE, enquanto o HAR-RV é estimado por mínimos quadrados sobre a volatilidade e minimiza diretamente uma perda quadrática na escala avaliada. Os modelos

de árvores, por sua vez, foram treinados com erro quadrático sobre a volatilidade e não incorporam a assimetria da QLIKE, que penaliza fortemente a subestimação da variância. Esse alinhamento, discutido por Patton (2011) e Hansen and Lunde (2006), explica por que cada referência vence na escala para a qual foi estimada e por que a ordenação depende da função de perda.

A terceira é a estabilidade temporal das relações. As variáveis externas mais importantes nos modelos, os níveis de juros, evoluem lentamente e acompanham tendências de longo prazo. Em árvores ajustadas em janela crescente, essas variáveis permitem particionar a amostra por período, o que melhora o ajuste dentro da amostra mas não se generaliza para anos de teste com níveis de juros fora do intervalo histórico. A combinação entre alta importância SHAP e perda fora da amostra é compatível com esse mecanismo.

4.2. Valor condicional da informação externa

O resultado de regimes oferece uma interpretação mais precisa do papel da informação financeira. A literatura de conectividade mostra que a transmissão de volatilidade entre commodities e mercados financeiros se intensifica em crises e períodos de estresse (Singh and Kumar, 2026; Zhou et al., 2026). Os resultados deste estudo são consistentes com essa evidência em escala local: a informação financeira prejudica a previsão quando a volatilidade local é baixa e acrescenta informação quando ela é elevada. Em períodos calmos, variações de câmbio, juros ou índices acionários são interpretadas pelos modelos como sinais de risco que não se materializam nas cotações locais, o que produz previsões excessivamente voláteis. Em períodos turbulentos, a integração entre mercados aumenta e esses sinais passam a conter informação relevante.

A informação cross-commodity apresentou comportamento distinto, com ganhos pequenos e estáveis entre regimes. As variáveis desse bloco com maior importância, o indicador CEPEA e o contrato internacional de café, estão diretamente ligadas à formação do preço local. Ainda assim, mesmo duas praças da mesma variedade, sujeitas às mesmas referências de mercado, apresentam correlação de apenas 0,137 entre seus retornos e variações simultâneas de preço em apenas 5,38% das datas comuns. Esse padrão indica que as cotações locais incorporam as referências de mercado com atraso e de forma irregular, o que limita o conteúdo preditivo contemporâneo das variáveis externas. Esse resultado é compatível com a evidência de que políticas e condições locais têm capacidade limitada de conter oscilações determinadas por forças externas, mas também de que a transmissão dessas forças aos mercados regionais não é imediata (Fahmi et al., 2023; Aliaga-Miranda et al., 2026).

Por fim, a estabilidade do GARCH entre os períodos de estresse contrasta com a evidência de que especificações GARCH tradicionais podem apresentar limitações em períodos de instabilidade (Brun, 2026). No presente contexto, a vantagem do GARCH em QLIKE foi mantida antes de 2020, no choque da COVID-19, na crise de geada e oferta de 2021–2022 e no período posterior. Essa diferença pode refletir o fato de que o presente estudo avalia a previsão de variância agregada em horizontes curtos, e não medidas de risco extremo.

4.3. Implicações práticas

Para produtores, cooperativas e agentes de comercialização, os resultados sugerem uma seleção de modelos orientada pela finalidade da previsão. Quando o objetivo é dimensionar o risco em termos de variância, como no cálculo de margens ou medidas de valor em risco, o GARCH(1,1) oferece a referência mais confiável. Quando o objetivo é antecipar a magnitude típica das variações, o HAR-RV apresenta os menores erros. A inclusão de variáveis externas em modelos de machine learning não deve ser tratada como melhoria automática. Informações cross-commodity podem ser mantidas por seu custo baixo e ganho marginal, enquanto informações financeiras só se justificam em períodos de volatilidade elevada, o que sugere estratégias de combinação ou de seleção condicionadas ao regime.

4.4. Limitações

Os resultados devem ser interpretados à luz de algumas limitações. Primeiro, as cotações locais são pouco frequentes e contêm lacunas longas, de modo que a volatilidade observada é dominada por saltos esparsos e por alvos nulos. Embora as análises de robustez mostrem que a ordenação dos modelos não depende do tratamento desses alvos, uma modelagem em duas etapas, separando a probabilidade de variação do preço e a magnitude da variação, poderia capturar melhor essa estrutura. Segundo, os modelos de machine learning foram estimados com hiperparâmetros fixos e com perda quadrática sobre a volatilidade. Essa escolha preserva a comparabilidade entre conjuntos de informação, mas não esgota o potencial desses modelos, que poderiam ser ajustados por validação temporal aninhada ou treinados com perdas alinhadas à QLIKE. Terceiro, o GARCH foi estimado com inovações normais, e distribuições com caudas pesadas podem ser mais adequadas a séries com saltos. Quarto, as variáveis financeiras de juros entraram em nível, e as

importâncias nativas e SHAP foram calculadas dentro da amostra; o uso de variações e de importâncias por permutação fora da amostra permitiria separar melhor o valor preditivo do ajuste. Quinto, a junção temporal utiliza a última observação disponível até a data da cotação local, e não é possível verificar se o fechamento dos mercados externos na mesma data antecede a coleta da cotação da SEAGRI-BA. Sexto, o estudo cobre três séries de um único estado, e os contratos internacionais foram obtidos como séries contínuas do Yahoo Finance, cuja convenção de rolagem pertence à fonte. Por fim, a avaliação é estatística e não inclui medidas de valor econômico, como o desempenho de estratégias de proteção ou o teste de medidas de valor em risco.

4.5. Síntese da discussão

Em conjunto, a discussão indica que o desempenho inferior dos modelos de machine learning não decorre de uma falha isolada de especificação, mas da combinação entre séries locais com baixa densidade de informação, perdas de estimação desalinhadas das perdas de avaliação e variáveis externas cuja relação com a volatilidade local não é estável no tempo. Essa leitura também explica por que a informação externa não é uniformemente inútil. Seu valor aparece quando a integração entre mercados se intensifica, como nos períodos de alta volatilidade, e desaparece quando as cotações locais evoluem de forma desconectada dos mercados financeiros. A contribuição do estudo, portanto, não é apenas mostrar que modelos mais flexíveis e conjuntos de informação mais amplos não garantem previsões melhores, mas identificar em que condições e por quais mecanismos essa informação pode ser útil. As limitações apontadas definem a agenda para testar se esse padrão se mantém com modelos treinados para a perda relevante, com variáveis financeiras transformadas e com avaliações do valor econômico das previsões, questões retomadas na conclusão.

5. Conclusion

Este estudo avaliou se informações de outras commodities agrícolas e dos mercados financeiros melhoram a previsão fora da amostra da volatilidade futura dos preços locais de café Arábica e Conilon na Bahia. Utilizando três séries da SEAGRI-BA, quatro conjuntos de informação aninhados, modelos econométricos e de machine learning e validação temporal estrita, o estudo mostrou que a resposta é, em geral, negativa.

Os modelos econométricos estimados apenas com o histórico local permaneceram como as melhores referências: o GARCH(1,1) na escala de variância e o HAR-RV na escala de volatilidade. Esse resultado resistiu à variação do tratamento dos alvos nulos, à correção para múltiplas comparações e à decomposição por regimes e períodos de estresse. A informação cross-commodity produziu ganhos marginais e restritos ao Random Forest. A informação financeira piorou a previsão em média, mas apresentou valor condicional ao regime, prejudicando a previsão em períodos calmos e acrescentando informação em períodos de volatilidade elevada. A importância atribuída pelos modelos aos níveis de juros não se converteu em ganho fora da amostra, o que alerta para os riscos de interpretar a explicabilidade como evidência de valor preditivo.

Esses resultados indicam que, em mercados agrícolas locais com cotações pouco frequentes, a seleção de modelos deve ser orientada pela função de perda relevante para o usuário e comparada sistematicamente com referências econométricas. Pesquisas futuras podem explorar modelos em duas etapas para a ocorrência e a magnitude das variações de preço, funções de treinamento alinhadas à QLIKE, combinações de previsões condicionadas ao regime, representações da dependência dinâmica entre mercados e avaliações do valor econômico das previsões para produtores e cooperativas.

Disponibilidade de dados e código

Todas as séries utilizadas são públicas: cotações locais da SEAGRI-BA, indicadores do CEPEA, séries do Banco Central do Brasil, do Federal Reserve Economic Data e da U.S. Energy Information Administration e contratos contínuos do Yahoo Finance. Os códigos-fonte e materiais computacionais necessários à reprodução das análises estão abertos para consulta em repositório público: [A PREENCHER: [link](#) e DOI do repositório].

Declaração de interesses

[A PREENCHER pelos autores: declaração de interesses concorrentes.]

Financiamento

[A PREENCHER pelos autores: agências e números de processo, ou declaração de ausência de financiamento específico.]

Declaração de contribuição dos autores (CRediT)

[A PREENCHER pelos autores: papéis CRediT de cada autor, por meio do comando \credit{} após cada \author.]

References

- Aliaga-Miranda, A., Flores-Vilcapoma, L.R., Callupe-Cueva, P.C., Mariños-Alfaro, J.C., Visurraga-Camargo, L.A., Chavarry-Becerra, W.S., 2026. Cointegration and economic adjustment in agriculture: A vecm approach to coffee price shocks and macroeconomic dynamics. *Economies* 14, 156. <https://doi.org/10.3390/economies14050156>.
- Barunik, J., Křehlík, T., 2018. Measuring the frequency dynamics of financial connectedness and systemic risk. *Journal of Financial Econometrics* 16, 271–296. <https://doi.org/10.1093/jjfinec/nby001>.
- Benjamini, Y., Hochberg, Y., 1995. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)* 57, 289–300. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- Bollerslev, T., 1986. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics* 31, 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1).
- Bonato, M., Cepni, O., Gupta, R., Pierdzioch, C., 2024. Forecasting the realized volatility of agricultural commodity prices: Does sentiment matter? *Journal of Forecasting* 43, 2088–2125. <https://doi.org/10.1002/for.3106>.
- Breiman, L., 2001. Random forests. *Machine Learning* 45, 5–32. <https://doi.org/10.1023/A:1010933404324>.
- Brun, F., 2026. When garch is not enough: Volatility dynamics and extreme tail risk in coffee commodity markets. *International Review of Economics and Finance* 111. <https://doi.org/10.1016/j.iref.2026.105767>.
- Budris, C.A., Handro, P.O., Dima, B., 2025. 6 EXPLORING THE GARCH (1,1) MODEL WITH STUDENT-T INNOVATIONS IN A BAYESIAN FRAMEWORK: A CASE STUDY ON VIX VOLATILITY FORECASTING. *Romanian Journal of Economic Forecasting* 28, 94–112.
- Capitani, D.H.D., Gaio, L.E., 2025. Dynamic connectedness and volatility spillover in the Brazilian agricultural market in the context of the Covid-19 pandemic. *Estudos Economicos* 54. <https://doi.org/10.1590/1980-53575446dclg>.
- Carvalho, B.d.N., Souza Silva, A.K., da Costa Lobato, T., Martins Figueiredo, A., 2023. Análise da volatilidade dos retornos spot e futuro do café arábica no período de 2007 a 2017. *Revista de Economia* 43, 295–312. <https://doi.org/10.5380/re.v43i81.76292>.
- Chaovanapoonphol, Y., Singvejsakul, J., Wiboonpongse, A., 2023. Analysis of exogenous factors to thailand coffee price volatility: Using multiple exogenous bayesian garch-x model. *Agriculture* 13, 1973. <https://doi.org/10.3390/agriculture13101973>.
- Chen, T., Guestrin, C., 2016. Xgboost: A scalable tree boosting system, in: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794. <https://doi.org/10.1145/2939672.2939785>.
- Corsi, F., 2009. A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics* 7, 174–196. <https://doi.org/10.1093/jjfinec/nbp001>.
- da Costa Júnior, M.P., Khan, A.S., de Sousa, E.P., Sales Lima, P.V.P., 2015. Análise de Cointegração com Threshold nos Mercados Exportadores de Mel Natural no Brasil. *Revista de Economia e Sociologia Rural* 53, 305–320. <https://doi.org/10.1590/1234-56781806-9479005302007>.
- da Cunha, C.A., Wander, A.E., 2014. Asymmetry in farm-to-retail dry bean price transmission in São Paulo, Brazil. *Journal on Chain and Network Science* 14, 31–41. <https://doi.org/10.3920/JCNS2014.0233>.
- Diachkov, D., Ashofteh, A., 2026. A machine learning framework for short-horizon monitoring of systemic financial stress in europe. *Decision Analytics Journal* 20, 100742. <https://doi.org/10.1016/j.dajour.2026.100742>.
- Diebold, F.X., Mariano, R.S., 1995. Comparing predictive accuracy. *Journal of Business & Economic Statistics* 13, 253–263. <https://doi.org/10.1080/07350015.1995.10524599>.
- Diebold, F.X., Yilmaz, K., 2012. Better to give than to receive: Predictive directional measurement of volatility spillovers. *International Journal of Forecasting* 28, 57–66. <https://doi.org/10.1016/j.ijforecast.2011.02.006>.
- Diebold, F.X., Yilmaz, K., 2014. On the network topology of variance decompositions: Measuring the connectedness of financial firms. *Journal of Econometrics* 182, 119–134. <https://doi.org/10.1016/j.jeconom.2014.04.012>.
- Fahmi, C., Febriani, R.P., Rasyid, L.M., Hakim, A.L., 2023. The role of local government in maintaining coffee prices volatility in gayo highland of indonesia. *PETITA: Jurnal Kajian Ilmu Hukum dan Syariah* 8. <https://doi.org/10.22373/petita.v8i1.168>.
- Guindani, L.G., Oliveirai, G.A., Ribeiro, M.H.D.M., Gonzalez, G.V., de Lima, J.D., 2024. Exploring current trends in agricultural commodities forecasting methods through text mining: Developments in statistical and artificial intelligence methods. *Heliyon* 10. <https://doi.org/10.1016/j.heliyon.2024.e40568>.
- Hamulczuk, M., Pawlak, K., Czech, K., 2026. Price and trade dynamics in agricultural commodity markets.
- Hansen, P.R., Lunde, A., 2006. Consistent ranking of volatility models. *Journal of Econometrics* 131, 97–121. <https://doi.org/10.1016/j.jeconom.2005.01.005>.
- Harvey, D., Leybourne, S., Newbold, P., 1997. Testing the equality of prediction mean squared errors. *International Journal of Forecasting* 13, 281–291. [https://doi.org/10.1016/S0169-2070\(96\)00719-4](https://doi.org/10.1016/S0169-2070(96)00719-4).
- Holm, S., 1979. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics* 6, 65–70.

- Jin, B., Xu, X., 2024. Machine learning coffee price predictions. *Journal of Uncertain Systems* 17. <https://doi.org/10.1142/S1752890924500235>.
- Jin, B., Xu, X., 2026. Machine learning-driven forecasting of composite wholesale price indices for agricultural commodities in the vegetable basket project. *Quality & Quantity* 60, 10307–10357. <https://doi.org/10.1007/s11135-026-02650-z>.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.Y., 2017. Lightgbm: A highly efficient gradient boosting decision tree, in: *Advances in Neural Information Processing Systems*, pp. 3146–3154.
- Khemakhem, I., Gallas, S., 2025. Geopolitical turbulence and market dynamics: analyzing the impact of the Israeli–Hamas conflict on global market volatility. *China Finance Review International* <https://doi.org/10.1108/CFRI-09-2024-0538>.
- Kumar, A., Tripti, K., 2026. Machine learning methods for financial time series prediction: techniques and challenges. *Connecting Intelligence: Trends in Computation and Data Communication*, 475–480 <https://doi.org/10.1201/9781003773504-81>.
- Kupabado, M.M., Kaehler, J., 2025. Price effects of commodity financialization: Review of the evidence. *Journal of Economic Surveys* 39, 352–374.
- Lambert, L.H., Schoeneman, J.P., Lambert, D.M., Brien, M.W., 2025. Road networks and food price volatility. *Global Food Security* 47. <https://doi.org/10.1016/j.gfs.2025.100884>.
- Lundberg, S.M., Lee, S.I., 2017. A unified approach to interpreting model predictions, in: *Advances in Neural Information Processing Systems*, pp. 4765–4774.
- Ma, Y., Wei, B., 2025. Extreme conditional tail risk inference in ARMA–GARCH models. *Journal of Economic Dynamics and Control* 177. <https://doi.org/10.1016/j.jedc.2025.105128>.
- Manogna, R.L., Dharmaji, V., Sarang, S., 2025. A novel hybrid neural network-based volatility forecasting of agricultural commodity prices: empirical evidence from india. *Journal of Big Data* 12. <https://doi.org/10.1186/s40537-025-01131-8>.
- Marín-Rodríguez, N.J., González-Ruiz, J.D., Botero, S., 2025. Connectedness of Agricultural Commodities Under Climate Stress: Evidence from a TVP-VAR Approach. *Sci* 7. <https://doi.org/10.3390/sci7030123>.
- Martin, S.J., Clapp, J., 2015. Finance for agriculture or agriculture for finance? *Journal of Agrarian change* 15, 549–559.
- Maulana, E.D., Sumarminingsih, E., Nurjannah, N., Astuti, A.B., Astutik, S., 2026. Bayesian IGARCH Modeling of Jakarta Composite Index Volatility Using Hamiltonian Monte Carlo Algorithm. *Science and Technology Indonesia* 11, 261–279. <https://doi.org/10.26554/sti.2026.11.1.261-279>.
- Mohamed, S.D., Ismail, M.T., Majahar Ali, M.K., 2025. Improving and evaluating GARCH-type models for Bitcoin volatility prediction. *Eurasian Economic Review* 15, 1219–1260. <https://doi.org/10.1007/s40822-025-00328-9>.
- Naivasha, P., Musumba, G.W., Gikunda, P.K., Wandeto, J.M., 2026. Model-based evaluation of synthetic financial time series data: A comparative study with multi-metric validation. *Array* 29. <https://doi.org/10.1016/j.array.2026.100684>.
- Nassani, A.A., Imran, M., Khan, S., Zaman, K., Khan, H.U.R., Haffar, M., 2025. Financial integration and economic growth: impact of renewable energy investments, technology transfer, and climate change on europe and central asian economies. *Financial Innovation* 11, 41. <https://doi.org/10.1186/s40854-024-00733-0>.
- Nayak, G.H.H., Alam, M.W., Singh, K.N., Avinash, G., Kumar, R.R., Ray, M., Deb, C.K., 2024. Exogenous variable driven deep learning models for improved price forecasting of top crops in india. *Scientific Reports* 14. <https://doi.org/10.1038/s41598-024-68040-3>.
- Nelson, D.B., 1991. Conditional heteroskedasticity in asset returns: A new approach. *Econometrica* 59, 347–370. <https://doi.org/10.2307/2938260>.
- Newey, W.K., West, K.D., 1987. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica* 55, 703–708. <https://doi.org/10.2307/1913610>.
- Nhlapho, W., Atemkeng, M.T., Ndogmo, J.C., 2025. An attention-guided hybrid statistical and deep learning modeling for enhanced time series forecasting: A case study of South African telecommunication companies. *Scientific African* 30. <https://doi.org/10.1016/j.sciaf.2025.e02950>.
- Pandit, P., Sagar, A., Ghose, B., Paul, M., Kisi, O., Vishwakarma, D.K., Mansour, L., Yadav, K.K., 2024. Hybrid modeling approaches for agricultural commodity prices using ceemdan and time delay neural networks. *Scientific Reports* 14. <https://doi.org/10.1038/s41598-024-74503-4>.
- Pattat, A.J., 2011. Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics* 160, 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>.
- Rahayu, M.F., Chang, W.I., Anindita, R., 2015. Volatility analysis and volatility spillover analysis of indonesia's coffee price using arch/garch, and egarch model. *Journal of Agricultural Studies* 3. <https://doi.org/10.5296/jas.v3i2.7185>.
- R.L., M., Lahiri, P., 2025. The dynamic nexus between futures basis in indian and global agricultural markets. *Journal of Modelling in Management* 20, 1937–1957. <https://doi.org/10.1108/JM2-06-2024-0198>, [arXiv:https://www.emerald.com/jm2/article-pdf/20/6/1937/10670166/jm2-06-2024-0198en.pdf](https://www.emerald.com/jm2/article-pdf/20/6/1937/10670166/jm2-06-2024-0198en.pdf).
- Salisu, A.A., AbdulHakeem, A.H., 2026. The US-China tension, global supply disruptions and the agricultural commodity markets: a dynamic multivariate panel data analysis. *Journal of Economic Studies*, 1–17 <https://doi.org/10.1108/JES-10-2025-0832>.
- Salisu, A.A., Ogbonna, A.E., Gupta, R., Bouri, E.I., 2025. Forecasting spot and futures price volatility of agricultural commodities: The role of climate-related migration uncertainty. *Research in International Business and Finance* 80. <https://doi.org/10.1016/j.ribaf.2025.103133>.
- Seo, M., Jeong, W., Kim, G., Lee, S., 2026. Conditional continuous quantile forecasting under rough and heavy-tailed market dynamics. *Expert Systems with Applications* 324. <https://doi.org/10.1016/j.eswa.2026.132464>.
- Singh, V.K., Kumar, P., 2026. Crude oil and soft commodities volatility spillover patterns and portfolio diversification strategies in times of oil crises. *Financial Innovation* 12, 76. <https://doi.org/10.1186/s40854-025-00851-3>.
- Torre, T.F., Tonin, J.M., Oñate-Paredes, C.A., 2025. Transmission of risk and volatility in the Paraná livestock market: an application of the TVP-VAR model. *Revista de Economía e Sociología Rural* 63. <https://doi.org/10.1590/1806-9479.2025.293824>.

- Wang, G.J., Chen, Y., Zhu, Y., Xie, C., 2024. Systemic risk prediction using machine learning: Does network connectedness help prediction? *International Review of Financial Analysis* 93, 103147. <https://doi.org/10.1016/j.irfa.2024.103147>.
- Zhang, X., Zhang, R., Lee, C.C., 2025. Climate risks in main producing areas and realized volatility in agricultural futures: Machine learning methods based on high-frequency data. *Journal of Futures Markets* 45, 2034–2065. <https://doi.org/10.1002/fut.70027>.
- Zhou, X., Ouyang, Z., Gupta, R., Ji, Q., 2026. Time-varying multilayer networks analysis of frequency connectedness in commodity futures markets. *Empirical Economics* 70, 22. <https://doi.org/10.1007/s00181-026-02886-6>.